

Classwork – ML2

Model Evaluation, Model Training Process, Overfitting and Dataset Splitting

موضوع کلی

در این CW می‌خواهیم مفاهیم اصلی جلسه‌ی ML2 را با Python و NumPy تمرین کنیم.

تمرکز این تمرین روی موارد زیر است:

- Prediction •
- Ground Truth •
- Accuracy •
- Error Rate •
- False Positive •
- False Negative •
- Imbalanced Dataset •
- Model as a Mathematical Function •
- Weights and Bias •
- Loss •
- Optimization •
- Model Training Process •
- Preprocessing •
- Overfitting •
- Underfitting •
- Bias •

- Variance
- Train / Validation / Test Split
- Data Leakage
- Generalization

راهنمای سطح سوال‌ها

- Core: سوال‌های اصلی
- Stretch: سوال‌های کمی چالشی‌تر
- 🎁 Bonus: سوال اختیاری برای گروه‌هایی که زمان اضافه دارند

بخش 1 ● Validation Set

Scenario

یک junior developer داده‌ها را فقط به دو بخش تقسیم می‌کند:

Training Set

Test Set

او هیچ Validation Set نمی‌سازد.

مدل را برای 500 epochs آموزش می‌دهد.

بعد از تمام شدن training ، برای اولین بار مدل را روی Test Set ارزیابی می‌کند.

نتیجه‌ی Test Accuracy بسیار ضعیف است.

Reflection Questions

1. چرا حذف کردن Validation Set باعث شد developer در طول training وضعیت مدل را درست نبیند؟

2. چطور داشتن یک Validation Set می‌توانست قبل از رسیدن به final test باعث صرفه‌جویی در زمان شود؟

3. در یک markdown cell توضیح دهید چرا Test Set نباید در طول training چندین بار استفاده شود.

4. اگر developer چندین بار model را تغییر دهد و هر بار عملکرد را روی Test Set بررسی کند، چه مشکلی ممکن است ایجاد شود؟

● بخش 1 – B محاسبه‌ی Split Size با NumPy

فرض کنید یک dataset شامل 10,000 نمونه داریم. یک داده‌ی رندم بسازید و به عنوان دیتاست استفاده کنید. 10000 نمونه شامل 5 فیچر و یک لیبل می‌خواهیم آن را به شکل زیر تقسیم کنیم:

Training Set: 80%

Validation Set: 10%

Test Set: 10%

1. با استفاده از Python و NumPy تعداد samples های هر بخش را حساب کنید.

2. خروجی باید شبیه این باشد:

Training samples: ...

Validation samples: ...

Test samples: ...

Total: ...

3. بررسی کنید مجموع سه بخش دقیقاً برابر با تعداد کل dataset باشد.

4. حالا همین کار را برای dataset با 12,350 sample انجام دهید.
دقت کنید ممکن است درصدها عدد اعشاری بسازند. باید تعداد sample ها عدد صحیح باشد.

5. در یک comment توضیح دهید چرا تعداد sample ها باید integer باشد.

بخش 2 ● Prediction vs Ground Truth

در ML2 گفتیم evaluation یعنی مقایسه‌ی Prediction با Ground Truth.
داده‌ی زیر نتیجه‌ی یک مدل ساده برای دسته‌بندی customer support tickets است.

```
import numpy as np

ground_truth = np.array([
    "Normal",
    "Urgent",
    "Normal",
    "Spam",
    "Urgent",
    "Normal",
    "Spam",
    "Normal"
])
```

```
predictions = np.array([
    "Normal",
```

"Normal",
"Normal",
"Spam",
"Urgent",
"Spam",
"Spam",
"Normal"

])

1. آرایه‌ی `ground_truth` را چاپ کنید.
2. آرایه‌ی `predictions` را چاپ کنید.
3. با مقایسه‌ی این دو آرایه، یک `Boolean array` به نام `correct_mask` بسازید.
4. مقدار `correct_mask` را چاپ کنید.
5. تعداد `prediction` های درست را حساب کنید.
6. تعداد `prediction` های غلط را حساب کنید.
7. در یک `markdown cell` توضیح دهید:
 - `Prediction` یعنی چه؟
 - `Ground Truth` یعنی چه؟
 - چرا بدون `Ground Truth` نمی‌توانیم `performance` مدل را اندازه‌گیری کنیم؟

بخش 3 ● Accuracy and Error Rate –

در این بخش با استفاده از داده‌های بخش قبل، `Accuracy` و `Error Rate` را محاسبه می‌کنیم.

فرمول: `Accuracy`

$\text{Accuracy} = \text{Number of Correct Predictions} / \text{Total Samples}$

فرمول: Error Rate

$\text{Error Rate} = \text{Number of Wrong Predictions} / \text{Total Samples}$

یا:

$\text{Error Rate} = 1 - \text{Accuracy}$

1. مقدار accuracy را حساب کنید.

2. مقدار error_rate را حساب کنید.

3. هر دو مقدار را به درصد چاپ کنید.

4. بررسی کنید آیا رابطه‌ی زیر درست است یا نه:

$\text{Accuracy} + \text{Error Rate} = 1$

5. اگر یک مدل $\text{Accuracy} = 92\%$ داشته باشد، مقدار Error Rate چقدر است؟

6. اگر یک مدل $\text{Error Rate} = 35\%$ داشته باشد، مقدار Accuracy چقدر است؟

بخش 4 ● – The Imbalance Trap

در ML2 گفتیم گاهی Accuracy به تنهایی گمراه‌کننده است، مخصوصاً وقتی dataset نامتعادل یا imbalanced باشد.

Scenario

ما ۱۰۰۰ ticket داریم:

- ۹۵۰ ticket از نوع "Normal" هستند.

- ۵۰ ticket از نوع "Urgent" هستند.

یک lazy model همه‌ی ticket ها را بدون خواندن متن، "Normal" پیش‌بینی می‌کند.

1. با NumPy آرایه‌ی y_true بسازید که شامل ۹۵۰ مقدار "Normal" و ۵۰ مقدار "Urgent" باشد.

2. آرایه‌ی `y_pred` بسازید که برای همه‌ی ۱۰۰۰ نمونه مقدار "Normal" داشته باشد.
 3. مقدار `Accuracy` را حساب کنید.
 4. مقدار `Error Rate` را حساب کنید.
 5. تعداد `tickets` های "Urgent" که اشتباه "Normal" پیش‌بینی شده‌اند را حساب کنید.
 6. در یک `markdown cell` توضیح دهید:
 - چرا این مدل با وجود `Accuracy` بالا، مدل خوبی نیست؟
 - چرا در `dataset` های `imbalanced` نباید فقط به `Accuracy` نگاه کنیم؟
 - اگر `tickets` های `Urgent` خیلی مهم باشند، این مدل چه خطری دارد؟
-

بخش 5 ● – Medical Diagnosis: False Positive vs False Negative

در `ML2` مثال `medical diagnosis` بررسی شد.
در `healthcare` ، نوع `error` خیلی مهم است.
داده‌ی زیر مربوط به ۵ بیمار است.

```
patient_id = np.array([1, 2, 3, 4, 5])  
ground_truth = np.array([  
    "Healthy",  
    "Malignant",  
    "Healthy",  
    "Healthy",  
    "Malignant"  
])
```

```
predictions = np.array([  
    "Healthy",  
    "Malignant",  
    "Malignant",  
    "Healthy",  
    "Healthy"  
])
```

در این سوال کلاس مهم را "Malignant" در نظر بگیرید.

1. برای هر بیمار مشخص کنید prediction درست بوده یا غلط.

2. مقدار Accuracy را حساب کنید.

3. مقدار Error Rate را حساب کنید.

4. تعداد False Positive را حساب کنید.

راهنمایی:

False Positive:

Prediction = Malignant

Ground Truth = Healthy

5. تعداد False Negative را حساب کنید.

راهنمایی:

False Negative:

Prediction = Healthy

Ground Truth = Malignant

6. مشخص کنید کدام patient مربوط به False Positive است.

7. مشخص کنید کدام patient مربوط به False Negative است.

8. در یک markdown cell توضیح دهید:

- در medical diagnosis ، False Negative خطرناکتر است یا False Positive ؟
- چرا؟
- آیا دو مدل با Accuracy برابر همیشه به یک اندازه خوب هستند؟

بخش 6 ● Spam Detection: Different Cost of Error

حالا همان ایده را در spam detection بررسی می‌کنیم.

```
email_id = np.array([1, 2, 3, 4, 5])
```

```
ground_truth = np.array([
```

```
    "Not Spam",
```

```
    "Spam",
```

```
    "Not Spam",
```

```
    "Not Spam",
```

```
    "Spam"
```

```
])
```

```
predictions = np.array([
```

```
    "Not Spam",
```

```
    "Spam",
```

```
    "Spam",
```

```
    "Not Spam",
```

```
    "Not Spam"
```

l)

در این سوال کلاس مهم را "Spam" در نظر بگیرید.

1. برای هر email مشخص کنید prediction درست بوده یا غلط.

2. مقدار Accuracy را حساب کنید.

3. مقدار Error Rate را حساب کنید.

4. تعداد False Positive را حساب کنید.

5. تعداد False Negative را حساب کنید.

6. مشخص کنید Email #3 چه نوع error ای دارد.

7. مشخص کنید Email #5 چه نوع error ای دارد.

8. در یک markdown cell توضیح دهید:

○ در spam detection ، False Positive چه مشکلی ایجاد می‌کند؟

○ False Negative چه مشکلی ایجاد می‌کند؟

○ به نظر شما در محیط business کدام یک خطرناک‌تر است؟ چرا؟

بخش 7 ● – Model as a Mathematical Function

در ML2 گفتیم یک model را می‌توان به شکل یک mathematical function دید:

Input $X \rightarrow$ Model $f(X) \rightarrow$ Output Y

در این بخش یک مدل ساده برای پیش‌بینی final exam score می‌سازیم.

فرمول مدل:

$$\text{predicted_score} = X1 * \text{Weight1} + X2 * \text{Weight2} + \text{Bias}$$

تعریف feature ها:

$X1 = \text{study_hours}$

```
X2 = gaming_hours_before_exam
```

داده:

```
study_hours = np.array([1, 2, 3, 5, 7, 8])
```

```
gaming_hours = np.array([6, 5, 4, 3, 2, 1])
```

```
actual_scores = np.array([35, 40, 50, 68, 82, 90])
```

پارامترهای مدل:

```
weight1 = 8
```

```
weight2 = -3
```

```
bias = 45
```

1. با استفاده از فرمول بالا، `predicted_scores` را حساب کنید.

2. مقدار `predicted_scores` را چاپ کنید.

3. اگر بعضی `prediction` ها کمتر از ۰ یا بیشتر از ۱۰۰ شدند، آن‌ها را با `np.clip` بین ۰ و ۱۰۰ نگه دارید.

4. مقدار `error` را حساب کنید.

```
error = predicted - actual
```

5. مقدار `absolute_error` را حساب کنید.

```
absolute_error = abs(predicted - actual)
```

6. مقدار `MAE` را حساب کنید.

```
MAE = mean(abs(predicted - actual))
```

7. در یک `markdown cell` پاسخ دهید:

○ چرا انتظار داریم `Weight1` مثبت باشد؟

○ چرا انتظار داریم Weight2 منفی باشد؟

○ Bias در این مدل چه مفهومی دارد؟

بخش 8 ● Weights and Bias as Knobs

در ML2 گفته شد پارامترهای مدل مثل knob هایی هستند که در training تنظیم می‌شوند.

در این بخش فقط مقدار weight1 را تغییر می‌دهیم و می‌بینیم کدام مقدار loss کم‌تری دارد.

از داده‌های بخش قبل استفاده کنید.

مقادیر candidate برای weight1:

```
candidate_weight1 = np.array([2, 4, 6, 8, 10, 12])
```

مقدارهای ثابت:

```
weight2 = -3
```

```
bias = 45
```

1. برای هر مقدار از candidate_weight1، prediction را حساب کنید.

راهنمایی:

خروجی می‌تواند یک matrix با shape زیر باشد:

```
(number_of_candidate_weights, number_of_samples)
```

2. برای هر candidate مقدار MAE را حساب کنید.

3. candidate ای که کم‌ترین MAE دارد پیدا کنید.

4. بهترین مقدار weight1 را چاپ کنید.

5. در یک markdown cell توضیح دهید:

○ چرا این کار شبیه یک optimization ساده است؟

○ در training واقعی، optimizer چه کاری انجام می‌دهد؟

○ آیا optimizer مستقیماً accuracy را زیاد می‌کند یا loss/error را کم می‌کند؟

● بخش 9: Preprocessing – تبدیل Text به Numeric Features

در ML2 گفتیم کامپیوتر raw text را مستقیماً نمی‌فهمد.
پس باید داده را به عدد تبدیل کنیم. این مرحله Preprocessing نام دارد.
داده‌ی زیر چند customer email ساده است:

```
emails = np.array([
    "URGENT reset my password now!!!",
    "hello I have a question about my invoice",
    "refund refund refund this is unacceptable!!!",
    "please cancel my subscription",
    "thank you for your help",
    "URGENT billing error please help!!!"
])

labels = np.array([
    "Urgent",
    "Normal",
    "Urgent",
    "Normal",
    "Normal",
    "Urgent"
])
```

می‌خواهیم از هر email چند feature عددی بسازیم:

feature 1: آیا کلمه urgent داخل متن وجود دارد؟ 1 یا 0

feature 2: آیا کلمه refund داخل متن وجود دارد؟ 1 یا 0

feature 3: تعداد علامت ! در متن

feature 4: تعداد کلمات متن

1. با استفاده از Python loop و string methods این feature ها را برای هر email حساب کنید.

2. یک NumPy array به نام X_email بسازید که shape آن به شکل زیر باشد:

(6, 4)

3. مقدار X_email را چاپ کنید.

4. در یک comment بنویسید هر ستون نشان‌دهنده‌ی چه feature ای است.

5. در یک markdown cell توضیح دهید:

○ چرا این مرحله preprocessing است؟

○ چرا model به جای raw text به عدد نیاز دارد؟

بخش 10 ● Rule-based Model on Preprocessed Emails

حالا با feature هایی که در بخش قبل ساختید، یک rule-based model ساده بسازید.

قانون:

اگر یکی از شرط‌های زیر برقرار باشد، email را "Urgent" پیش‌بینی کنید:

```
urgent_word == 1
```

```
refund_word == 1
```

```
exclamation_count >= 3
```


در غیر این صورت، email را "Normal" پیش‌بینی کنید.

1. با استفاده از X_email سه feature مورد نیاز را جدا کنید.
2. با استفاده از Boolean operations و np.where آرایه‌ی email_predictions را بسازید.
3. مقدار email_predictions را چاپ کنید.
4. مقدار Accuracy را با مقایسه‌ی email_predictions و labels حساب کنید.
5. مقدار Error Rate را حساب کنید.
6. در یک markdown cell توضیح دهید:

- این model واقعا Machine Learning است یا Rule-based AI ؟
- چرا؟
- اگر بخواهیم این مسئله را به Machine Learning تبدیل کنیم، مدل باید چه چیزی را از داده یاد بگیرد؟

● بخش 11 Model Training Process – با یک مثال ساده

در ML2 فرآیند training به شکل زیر توضیح داده شد:





Optimization



Updated Model

↺ Repeat

در این بخش یک simulation ساده از training داریم.
فرض کنید یک مدل فقط یک parameter به نام w دارد:

```
prediction = X * w
```

داده:

```
X = np.array([1, 2, 3, 4, 5])
```

```
y = np.array([3, 6, 9, 12, 15])
```

مقادیر مختلف برای w :

```
candidate_w = np.array([1, 2, 2.5, 3, 3.5, 4])
```

1. برای هر مقدار w ، prediction را حساب کنید.

2. برای هر مقدار w ، مقدار MSE را حساب کنید.

فرمول: MSE:

```
MSE = mean((prediction - y) ** 2)
```

3. مقدار w ای که کمترین MSE دارد پیدا کنید.

4. بهترین w را چاپ کنید.

5. در یک markdown cell توضیح دهید:

○ در این مثال Data چیست؟

○ Model چیست؟

○ Prediction چیست؟

○ Loss چیست؟

○ Optimization در این تمرین چگونه انجام شد؟

○ Updated Model یعنی چه؟

بخش 12 ● Detecting Overfitting with Validation Accuracy –

در ML2 گفتیم اگر Training Accuracy زیاد شود ولی Validation Accuracy شروع به افت کند، ممکن است model دچار Overfitting شده باشد.

داده‌ی زیر accuracy مدل را در طول epoch ها نشان می‌دهد.

```
epochs = np.array([1, 2, 3, 4, 5, 6, 7, 8, 9, 10])
```

```
train_accuracy = np.array([0.55, 0.63, 0.70, 0.78, 0.85, 0.90, 0.94, 0.97, 0.99, 1.00])
```

```
validation_accuracy = np.array([0.52, 0.60, 0.68, 0.75, 0.82, 0.84, 0.83, 0.79, 0.74, 0.70])
```

1. بهترین epoch را براساس بیشترین validation_accuracy پیدا کنید.

2. مقدار train accuracy و validation accuracy در بهترین epoch را چاپ کنید.

3. از چه epoch ای به بعد validation accuracy شروع به کم شدن می‌کند؟

4. در همان زمان train accuracy چه رفتاری دارد؟

5. در یک markdown cell توضیح دهید:

○ چرا این وضعیت نشانه‌ی Overfitting است؟

○ چرا نباید فقط به train accuracy نگاه کنیم؟

○ Early Stopping در این مثال یعنی چه؟

بخش 13 ● Underfitting, Good Fit, Overfitting –

سه model مختلف داریم.

```
models = np.array(["Model A", "Model B", "Model C"])
```

```
train_error = np.array([0.35, 0.08, 0.01])
```

```
test_error = np.array([0.38, 0.10, 0.35])
```

1. برای هر model مقدار gap را حساب کنید.

```
gap = test_error - train_error
```

2. مدلی را پیدا کنید که هم train error و هم test error بالا دارد.

3. این مدل بیشتر به Underfitting نزدیک است یا Overfitting؟

4. مدلی را پیدا کنید که train error خیلی پایین ولی test error بالا دارد.

5. این مدل بیشتر به Overfitting نزدیک است یا Underfitting؟

6. مدلی را پیدا کنید که train error و test error هر دو پایین و نزدیک به هم دارد.

7. این مدل را به عنوان Good Fit معرفی کنید.

8. در یک markdown cell توضیح دهید:

○ Underfitting یعنی چه؟

○ Overfitting یعنی چه؟

○ Good Fit یعنی چه؟

بخش 14 ● Bias vs Variance –

در ML2 گفتیم:

High Bias → Underfitting

High Variance → Overfitting

با استفاده از نتیجه‌ی بخش قبل به سوال‌های زیر پاسخ دهید.

1. کدام model احتمالا High Bias دارد؟
 2. کدام model احتمالا High Variance دارد؟
 3. کدام model balance بهتری بین bias و variance دارد؟
 4. در یک markdown cell توضیح دهید:
 - Bias در ML یعنی چه؟
 - Variance در ML یعنی چه؟
 - چرا مدل خیلی ساده ممکن است High Bias داشته باشد؟
 - چرا مدل خیلی پیچیده ممکن است High Variance داشته باشد؟
-

بخش 15 ● Train / Validation / Test Final Evaluation –

فرض کنید بعد از استفاده از Validation Set، بهترین model را انتخاب کرده‌ایم.

حالا final evaluation روی Test Set انجام شده است.

```
validation_accuracy = np.array([0.76, 0.82, 0.87, 0.86, 0.84])
```

```
test_accuracy = 0.865
```

```
model_names = np.array([
```

```
    "Model 1",
```

```
    "Model 2",
```

"Model 3",

"Model 4",

"Model 5"

l)

1. بهترین model را براساس بیشترین validation accuracy پیدا کنید.
 2. نام بهترین model را چاپ کنید.
 3. مقدار validation accuracy بهترین model را چاپ کنید.
 4. مقدار test accuracy نهایی را چاپ کنید.
 5. بررسی کنید test accuracy به validation accuracy نزدیک است یا خیلی دور.
 6. در یک markdown cell توضیح دهید:
- اگر test accuracy خیلی کمتر از validation accuracy باشد، چه نگرانی‌ای داریم؟
 - اگر test accuracy نزدیک به validation accuracy باشد، چه نتیجه‌ای می‌گیریم؟
 - چرا test set باید فقط در پایان استفاده شود؟

بخش 16 ● Data Leakage –

در ML2 گفتیم اگر model به اطلاعاتی دسترسی داشته باشد که در دنیای واقعی نباید هنگام prediction در اختیارش باشد، ممکن است Data Leakage اتفاق بیفتد.

فرض کنید می‌خواهیم پیش‌بینی کنیم آیا یک دانشجو final exam را pass می‌کند یا نه.

داده:

```
# study_hours, attendance, previous_score, final_score
```

```
students = np.array([
```

```
[2, 60, 45, 50],
```

[5, 80, 70, 75],

[1, 40, 35, 38],

[8, 90, 88, 92],

[4, 75, 60, 65],

[7, 85, 80, 84]

])

1. سه ستون اول را به عنوان feature های سالم جدا کنید و در `X_clean` ذخیره کنید.

2. ستون آخر را به عنوان `final_score` جدا کنید.

3. از روی `final_score` یک label بسازید:

```
if final_score >= 60 → pass
```

```
else → fail
```

4. حالا یک `X_leaky` بسازید که علاوه بر سه feature اول، خود `final_score` را هم داخل feature ها داشته باشد.

5. در یک markdown cell توضیح دهید:

- چرا استفاده از `final_score` به عنوان feature برای پیش‌بینی `pass/fail` اشتباه است؟

- چرا این کار باعث `data leakage` می‌شود؟

- اگر مدل به `final_score` دسترسی داشته باشد، آیا `performance` واقعی مدل قابل اعتماد است؟

بخش 17 ● Final Summary –

در یک markdown cell به سوال‌های زیر پاسخ دهید:

1. Prediction چیست؟
 2. Ground Truth چیست؟
 3. Accuracy چیست؟
 4. Error Rate چیست؟
 5. چرا Accuracy همیشه کافی نیست؟
 6. False Positive چیست؟
 7. False Negative چیست؟
 8. در medical diagnosis کدام نوع error خطرناکتر است؟ چرا؟
 9. Model را چگونه می‌توان به صورت mathematical function دید؟
 10. Bias و Weight چه نقشی در model دارند؟
 11. Loss چیست؟
 12. Optimization چیست؟
 13. چرا preprocessing مهم است؟
 14. Overfitting چیست؟
 15. Underfitting چیست؟
 16. Bias و Variance چه ارتباطی با Underfitting و Overfitting دارند؟
 17. Training Set برای چیست؟
 18. Validation Set برای چیست؟
 19. Test Set برای چیست؟
 20. Data Leakage چیست؟
 21. Generalization یعنی چه؟
-

Bonus — Build a Small Evaluation Function

تابع زیر را کامل کنید:

```
def evaluate_classification(y_true, y_pred):
```

```
    """
```

```
    input:
```

```
        y_true: ground truth labels
```

```
        y_pred: model predictions
```

```
    output:
```

```
        accuracy
```

```
        error_rate
```

```
        number_of_correct_predictions
```

```
        number_of_wrong_predictions
```

```
    """
```

سپس این تابع را روی داده‌های زیر تست کنید:

```
y_true = np.array(["Normal", "Urgent", "Normal", "Spam", "Urgent"])
```

```
y_pred = np.array(["Normal", "Normal", "Normal", "Spam", "Spam"])
```

خروجی باید شامل موارد زیر باشد:

Accuracy: ...

Error Rate: ...

Correct Predictions: ...

Wrong Predictions: ...