

دیتاست مورد نیاز این جلسه رو از لینک زیر بردارید:

[Online class work.csv](#)

سؤال ۱ — شناخت ساختار دیتاست

دیتاست را با Pandas بخوانید:

```
import pandas as pd

df = pd.read_csv("online_orders_classwork.csv")
```

- پنج سطر اول دیتاست را نمایش دهید.
- اطلاعات کلی دیتاست را نمایش دهید.
- آمار توصیفی ستون‌های عددی را نمایش دهید.
- براساس خروجی `info()`، تعداد سطرها و ستون‌های دیتاست را بنویسید.
- نام ستون‌هایی را که نوع داده عددی دارند، از روی خروجی مشخص کنید.
- نام ستون‌هایی را که نوع داده آن‌ها `object` است، مشخص کنید.
- توضیح دهید هر سطر دیتاست نماینده چه چیزی است.
- توضیح دهید هر ستون دیتاست نماینده چه چیزی است.

سؤال ۲ — تشخیص نوع متغیرها

با استفاده از نوع هر یک از متغیرهای زیر را مشخص کنید:

متغیر	Continuous	Discrete	Categorical
City			
DeliveryMinutes			
ItemsCount			
PaymentMethod			
OrderValue			
Returned			

سپس به موارد زیر پاسخ دهید:

۱. چرا ItemsCount متغیر گسسته محسوب می شود؟
۲. چرا OrderValue متغیر پیوسته محسوب می شود؟
۳. چرا محاسبه میانگین برای ستون City معنا ندارد؟
۴. اگر هدف مسئله پیش بینی مبلغ سفارش باشد، Target کدام ستون است؟
۵. برای این مسئله، سه ستون را به عنوان Feature پیشنهاد دهید.

سؤال ۳ — بررسی فراوانی متغیرهای دسته‌ای

با استفاده از `value_counts()` موارد زیر را محاسبه کنید:

۱. تعداد سفارش‌های ثبت‌شده در هر شهر
۲. تعداد سفارش‌ها در هر دسته‌بندی محصول
۳. فراوانی هر روش پرداخت
۴. تعداد سفارش‌های مرجوع‌شده و مرجوع‌نشده

براساس خروجی‌ها، دقیقاً به این پرسش‌ها پاسخ دهید:

۱. کدام شهر بیشترین تعداد سفارش را دارد؟
۲. کدام دسته‌بندی کمترین تعداد سفارش را دارد؟
۳. پرتکرارترین روش پرداخت چیست؟
۴. چند سفارش مرجوع شده است؟
۵. آیا تعداد سفارش‌های مرجوع‌نشده بیشتر از سفارش‌های مرجوع‌شده است؟

سؤال ۴ — انتخاب Histogram یا Bar Chart

برای هر یک از ستون‌های زیر مشخص کنید استفاده از **Histogram** یا **Bar Chart** مناسب‌تر است و برای انتخاب خود یک دلیل کوتاه بنویسید:

دلیل	نمودار مناسب	ستون
		PaymentMethod
		DeliveryMinutes

سپس با استفاده از Pandas و Matplotlib (برای رسم نمودار ها از کد استاد استفاده کنید)

۱. نمودار مناسب ستون PaymentMethod را رسم کنید.
 ۲. نمودار مناسب ستون DeliveryMinutes را رسم کنید.
- پس از رسم نمودارها پاسخ دهید:
 - نمودار مناسب ستون PaymentMethod را رسم کنید.
 - نمودار مناسب ستون DeliveryMinutes را رسم کنید.
 - از روی نمودار PaymentMethod، پرتکرارترین روش پرداخت را مشخص کنید.
 - از روی نمودار DeliveryMinutes، مشخص کنید بیشتر سفارش ها در چه محدوده ای از زمان تحویل قرار دارند.
 - با هم گروهی هاتون صحبت کنید چرا برای این دو ستون از یک نوع نمودار استفاده نمی شود.

سؤال ۵ — بررسی توزیع مبلغ سفارش ها

برای ستون OrderValue یک Histogram با ۶ بازه رسم کنید. سپس میانگین و میانه این ستون را محاسبه کنید.

بر اساس خروجی ها پاسخ دهید:

۱. مقدار میانگین بزرگ تر است یا میانه؟
۲. از میان گزینه های زیر، کدام مورد شکل توزیع را بهتر توصیف می کند؟
 - نرمال
 - یکنواخت
 - راست چوله
 - چپ چوله
 - دو قله ای
۳. کدام مقدار موجود در ستون OrderValue باعث کشیده شدن دنباله توزیع شده است؟
۴. آیا بیشتر سفارش ها نزدیک مقدار ۹۰۰ هستند یا فاصله زیادی با آن دارند؟
۵. اگر مقدار ۹۰۰ حذف شود، انتظار دارید میانگین افزایش یابد یا کاهش؟

۶. برای گزارش مبلغ معمول سفارش‌ها، میانگین قابل‌اعتمادتر است یا میانه؟ دلیل را فقط براساس وجود مقدار بسیار بزرگ توضیح دهید.

سؤال ۶ — تحلیل Mean ، Median و Mode

برای ستون OrderValue میانگین، میانه و مد را محاسبه کنید. سپس مد ستون‌های PaymentMethod، City و Category را نیز به دست آورید.

براساس خروجی‌ها پاسخ دهید:

۱. میانگین OrderValue نشان‌دهنده چه مقداری در کل سفارش‌هاست؟
۲. میانه OrderValue دیتاست را به چند بخش تقسیم می‌کند؟
۳. مد PaymentMethod کدام روش پرداخت را نشان می‌دهد؟
۴. مد City کدام شهر را نشان می‌دهد؟
۵. آیا OrderValue دارای یک مد مشخص است؟ خروجی Pandas را بررسی کنید.
۶. برای ستون دسته‌ای PaymentMethod کدام شاخص مناسب است Mean ، Median یا Mode؟
۷. برای ستون عددی دارای داده پرت OrderValue، Mean یا Median کدام یک کمتر تحت تأثیر مقدار ۹۰۰ قرار گرفته است؟

سؤال ۷ — تحلیل Variance و Standard Deviation

واریانس و انحراف معیار ستون‌های زیر را محاسبه کنید:

- OrderValue
- DeliveryMinutes

• CustomerRating

سپس پاسخ دهید:

۱. اگر انحراف معیار یک ستون صفر باشد، مقادیر آن ستون چه وضعیتی دارند؟
۲. وجود مقدار ۹۰۰ باعث افزایش یا کاهش انحراف معیار OrderValue شده است؟
۳. در ستون CustomerRating، مقادیر به میانگین نزدیک‌ترند یا در دامنه بسیار بزرگی پخش شده‌اند؟
۴. چرا واریانس همیشه مقداری نامنفی است؟
۵. چرا تفسیر انحراف معیار معمولاً از واریانس ساده‌تر است؟
۶. آیا مقایسه مستقیم مقدار انحراف معیار OrderValue با CustomerRating مناسب است؟
پاسخ را با توجه به تفاوت واحد و مقیاس دو ستون بنویسید.

سؤال ۸ — Percentile و Quartile

برای ستون OrderValue مقادیر زیر را با `quantile()` محاسبه کنید:

- Q1 یا صدک ۲۵
- Q2 یا صدک ۵۰
- Q3 یا صدک ۷۵
- صدک ۹۰

سپس پاسخ دهید:

۱. آیا Q2 با مقدار Median برابر است؟ دو خروجی را با هم مقایسه کنید.
۲. تقریباً چند درصد سفارش‌ها مقداری کمتر یا مساوی Q1 دارند؟
۳. تقریباً چند درصد سفارش‌ها مقداری کمتر یا مساوی Q3 دارند؟
۴. صدک ۹۰ چه مرزی را در میان مبلغ سفارش‌ها نشان می‌دهد؟
۵. اگر یک سفارش بالاتر از صدک ۹۰ باشد، در میان ۱۰ درصد سفارش‌های گران‌تر قرار دارد یا ۹۰ درصد سفارش‌های ارزان‌تر؟
۶. آیا هر مقداری که بالاتر از صدک ۹۰ است الزماً Outlier محسوب می‌شود؟ پاسخ را با روش IQR مقایسه کنید.

سؤال ۹ — تشخیص Outlier با روش IQR

برای ستون OrderValue مراحل زیر را انجام دهید:

۱. Q1 را محاسبه کنید.
۲. Q3 را محاسبه کنید.
۳. IQR را از تفاضل Q3 و Q1 به دست آورید.
۴. کران پایین را محاسبه کنید.
۵. کران بالا را محاسبه کنید.
۶. سفارش‌هایی را که خارج از این دو کران قرار دارند، با فیلتر Pandas استخراج کنید.
۷. فقط پنج سطر اول داده‌های پرت را نمایش دهید.

سپس براساس خروجی پاسخ دهید:

با استفاده از روش IQR، داده پرت ستون OrderValue را شناسایی کنید. سپس پاسخ دهید:

۱. چند داده پرت شناسایی شده و OrderID مربوط به آن چیست؟
۲. مبلغ سفارش پرت چقدر است و از کران بالا بیشتر است یا از کران پایین کمتر؟
۳. چرا این مقدار روی Mean بیشتر از Median تأثیر می‌گذارد؟
۴. آیا پرت بودن این مقدار حتماً به معنی اشتباه بودن آن است؟ یک دلیل کوتاه بنویسید.

سؤال ۱۰ — Scatter Plot و Correlation

بین ستون‌های DeliveryMinutes و CustomerRating یک Scatter Plot رسم کنید و سپس ضریب همبستگی آن‌ها را محاسبه کنید.

براساس نمودار و مقدار ضریب همبستگی پاسخ دهید:

۱. علامت ضریب همبستگی مثبت است یا منفی؟
۲. با افزایش زمان تحویل، امتیاز مشتری معمولاً افزایش می‌یابد یا کاهش؟

۳. نقاط نمودار تقریباً از پایین چپ به بالا راست حرکت می‌کنند یا از بالا چپ به پایین راست؟
۴. رابطه را از نظر شدت در یکی از سه گروه ضعیف، متوسط یا قوی قرار دهید.
۵. آیا ضریب همبستگی دقیقاً برابر با منفی یک است؟
۶. آیا می‌توان نتیجه گرفت تمام مشتریانی که سفارششان دیر رسیده، امتیاز پایین داده‌اند؟
۷. آیا این رابطه ثابت می‌کند زمان تحویل تنها علت امتیاز پایین است؟

سؤال ۱۱ — مقایسه چند همبستگی

ضریب همبستگی جفت‌های زیر را جداگانه محاسبه کنید:

- CustomerRating و DeliveryMinutes
- OrderValue و ItemsCount
- OrderValue و DiscountPercent
- OrderValue و DeliveryMinutes

سپس:

۱. علامت هر چهار ضریب را گزارش کنید.
۲. کدام جفت قوی‌ترین رابطه مثبت را دارد؟
۳. کدام جفت قوی‌ترین رابطه منفی را دارد؟
۴. کدام جفت ضریب همبستگی نزدیک‌تری به صفر دارد؟
۵. برای جفتی که قوی‌ترین رابطه را دارد، یک Scatter Plot رسم کرده و نتیجه عددی را با نمودار مقایسه کنید.

سؤال ۱۲ Correlation Matrix

فقط ستون‌های عددی دیتاست را با `select_dtypes(include="number")` انتخاب کنید. سپس ماتریس همبستگی را محاسبه و با `imshow()` نمایش دهید.

در ادامه، همبستگی تمام ستون‌های عددی با `OrderValue` را از بیشترین به کمترین مرتب کنید.

براساس خروجی پاسخ دهید:

۱. نام ستون‌های موجود در ماتریس همبستگی را بنویسید.
۲. چرا ستون‌هایی مانند City و PaymentMethod در ماتریس وجود ندارند؟
۳. چرا تمام مقادیر قطر اصلی ماتریس برابر با یک هستند؟
۴. کدام متغیر بیشترین همبستگی مثبت را با OrderValue دارد؟
۵. کدام متغیر بیشترین همبستگی منفی را با OrderValue دارد؟
۶. چرا همبستگی OrderValue با خودش باید از فهرست انتخاب Feature کنار گذاشته شود؟
۷. آیا متغیری که بیشترین همبستگی را دارد، الزاماً علت افزایش مبلغ سفارش است؟
۸. آیا باید فقط براساس Correlation Matrix درباره انتخاب نهایی Feature تصمیم گرفت؟