

سؤال ۱ – تشخیص نوع مسئله و انتخاب مدل مناسب

الف) برای هر یک از سناریوهای زیر مشخص کنید:

1. مسئله از نوع Regression است یا Classification ؟
2. دلیل خود را در یک یا دو جمله توضیح دهید.

سناریوها:

الف) پیش‌بینی قیمت یک خانه بر اساس متراژ، تعداد اتاق و سن ساختمان.

ب) تشخیص اینکه یک ایمیل Spam است یا خیر.

ج) پیش‌بینی میزان مصرف برق یک ساختمان در روز آینده.

د) تشخیص گونه یک گل بر اساس طول و عرض گلبرگ.

هـ) پیش‌بینی مدت زمان رسیدن تاکسی به مقصد.

و) پیش‌بینی اینکه یک مشتری وام خود را بازپرداخت خواهد کرد یا خیر.

ب) برای هر یک از سناریوهای بالا، مناسب‌ترین الگوریتم از بین گزینه‌های زیر را انتخاب کنید.

- Linear Regression
- Logistic Regression
- KNN Regressor
- KNN Classifier
- Decision Tree Classifier
- K-Means

در صورت وجود بیش از یک انتخاب مناسب، دلیل انتخاب خود را بیان کنید.

ج) برای هر سناریو، مشخص کنید کدام معیار ارزیابی مناسب‌تر است.

از میان معیارهای زیر انتخاب کنید.

- Accuracy
- Confusion Matrix
- MSE
- MAE
- R^2

در صورت نیاز می‌توانید بیش از یک معیار انتخاب کنید.

(د) جدول زیر را کامل کنید.

نوع خروجی	نوع یادگیری	الگوریتم
؟	؟	Linear Regression
؟	؟	Logistic Regression
؟	؟	KNN Regressor
؟	؟	KNN Classifier
؟	؟	Decision Tree
؟	؟	K-Means

(ه) به پرسش‌های زیر پاسخ کوتاه دهید.

1. چرا Accuracy معیار مناسبی برای Linear Regression نیست؟
2. چرا R^2 برای طبقه‌بندی استفاده نمی‌شود؟
3. مهم‌ترین تفاوت خروجی Regression و Classification چیست؟

سؤال ۲ – آموزش مدل Regression

در این سؤال قصد داریم یک مدل Linear Regression برای پیش‌بینی قیمت خانه آموزش دهیم.

```
import pandas as pd

house_data = pd.DataFrame({

    "Area": [ 60,65,70,75,80,85,90,95,100,105,110,115,120,125,
130,135,140,145,150,155,160,165,170,175,180,185, 190,195,200,205,210,215,220,225,230,235,240,245,
250,255,260,265,270,275,280,285,290,295 ],

    "Bedrooms": [ 1,1,2,2,2,2,2,3,3,3,3,3,3,3, 4,4,4,4,4,4,4,4,5,5,5, 5,5,5,5,5,5,6,6,6,6,6,6, 6,6,7,7,7,7,7,7,7,7 ],

    "Age": [ 30,28,26,24,22,20,18,17,16,15,14,13,12,11, 10,9,8,8,7,7,6,6,5,5,4,4, 3,3,2,2,2,1,1,1,1,1,1,1,
1,1,1,1,1,1,1,1,1,1 ],

    "Price": [ 130,145,158,170,185,198,210,228,245,258,270,285,300,315,
328,340,355,365,375,392,400,410,425,438,450,462, 475,488,500,515,528,540,555,568,580,595,610,625,
640,652,665,680,695,708,720,735,750,765 ]

})
```

هدف، پیش‌بینی ستون Price است.

الف) ابتدا داده‌ها را بررسی کنید.

1. پنج سطر اول را نمایش دهید.
2. تعداد نمونه‌ها و تعداد ویژگی‌ها را مشخص کنید.
3. ویژگی‌ها (Features) و متغیر هدف (Target) را تعیین کنید.

ب) داده‌ها را به نسبت 80% آموزش و 20% آزمون تقسیم کنید.

از random_state=42 استفاده کنید.

ج) یک مدل Linear Regression آموزش دهید.

د) برای داده‌های آزمون، قیمت خانه‌ها را پیش‌بینی کنید.

ه) جدولی مشابه جدول زیر ایجاد کنید.

Actual Price	Predicted Price
...	...

و) برای یک خانه با مشخصات زیر قیمت را پیش‌بینی کنید.

- Area = 140
- Bedrooms = 4
- Age = 5

ز) به سؤال‌های زیر پاسخ دهید.

نکته: در این قسمت فقط استدلال کنید و نیازی به اجرای مجدد مدل نیست.

1. آیا همه ویژگی‌ها برای پیش‌بینی قیمت مفید به نظر می‌رسند؟
2. انتظار دارید کدام ویژگی بیشترین تأثیر را داشته باشد؟ چرا؟
3. اگر ویژگی **Age** را حذف کنیم، آیا انتظار دارید دقت مدل افزایش یابد یا کاهش؟ دلیل خود را بیان کنید.

سؤال ۳ – ارزیابی و تحلیل مدل Linear Regression

در این سؤال از مدل آموزش داده شده در سؤال قبل استفاده کنید.

الف) معیارهای زیر را برای داده‌های آزمون محاسبه کنید.

- Mean Absolute Error (MAE)
- Mean Squared Error (MSE)
- R^2 Score

ب) نمودار Actual vs Predicted را رسم کنید.

سپس به پرسش‌های زیر پاسخ دهید.

- آیا نقاط نزدیک خط ایده‌آل قرار گرفته‌اند؟
- اگر چند نقطه فاصله زیادی از خط داشته باشند، چه برداشتی می‌توان داشت؟
- اگر تمام نقاط دقیقاً روی خط باشند، مقدار R^2 تقریباً چند خواهد بود؟

ج) فرض کنید خروجی مدل به صورت زیر باشد.

Actual	Predicted
210	205
270	280
340	335
410	430

بدون استفاده از کد، مشخص کنید:

- کدام نمونه بیشترین خطا را دارد؟
- کدام نمونه کمترین خطا را دارد؟
- آیا مدل در مجموع عملکرد قابل قبولی دارد؟ دلیل خود را بیان کنید.

د) یکی نفر ادعا می‌کند:

«مدل من ۹۵٪ Accuracy دارد، بنابراین مدل Regression بسیار خوبی است.»

نظر ایشان را نقد کنید.

در پاسخ خود به موارد زیر اشاره کنید.

- چرا Accuracy برای Regression مناسب نیست؟
- به جای آن از چه معیارهایی باید استفاده کرد؟

- هر معیار چه اطلاعاتی درباره عملکرد مدل ارائه می‌دهد؟

ه) فرض کنید مقدار $R^2 = 0.94$ به دست آمده است.

به پرسش‌های زیر پاسخ دهید.

1. این مقدار چه برداشتی از کیفیت مدل به ما می‌دهد؟
2. آیا صرفاً با داشتن R^2 بالا می‌توان نتیجه گرفت که مدل همیشه خوب است؟ چرا؟
3. چه عواملی ممکن است باعث شوند مدلی با R^2 بالا در عمل عملکرد مطلوبی نداشته باشد؟

سؤال ۴ – آموزش مدل طبقه‌بندی با Logistic Regression

موضوع: تشخیص تراکنش‌های بانکی مشکوک (Fraud Detection)

Dataset:

```
import pandas as pd

transaction_data = pd.DataFrame({

    "Amount": [ 15,20,22,25,28,30,35,40,45,50,55,60,65,70,75,
80,90,100,110,120,130,140,150,160,180,200,220,250,280,300,
320,350,380,400,450,500,550,600,650,700,750,800,850,900,950,
1000,1050,1100,1150,1200,1250,1300,1350,1400,1450,1500,1600,1700,1800 ],

    "TransactionCount": [ 1,1,1,1,1,2,2,2,2,2,2,3,3,3, 3,3,3,3,4,4,4,4,4,5,5,5,5,6,6,
6,6,6,7,7,8,8,8,8,9,9,9,9,10,10, 10,10,11,11,11,12,12,12,13,13,14,14,15,15 ],

    "International": [ 0,0,0,0,0,0,0,0,0,0,0,0,0,0, 0,0,1,0,1,0,1,1,0,1,1,0,1,1,1,
0,1,1,0,1,1,1,0,1,1,0,1,1,0,1, 1,0,1,1,0,1,1,0,1,1,1,0,1,1 ],

    "Fraud": [ 0,0,0,0,0,0,0,0,0,0,0,0,0,0, 0,0,0,0,0,0,1,0,1,1,1,1,1,1,1, 1,1,1,1,1,1,1,1,1,1,1,1,1,1,1,
1,1,1,1,1,1,1,1,1,1,1,1,1 ]

})
```

ستون Fraud متغیر هدف است.

الف) ابتدا داده‌ها را بررسی کنید.

- پنج سطر اول را نمایش دهید.
- تعداد نمونه‌های هر کلاس (Fraud=0 و Fraud=1) را محاسبه کنید.
- آیا داده‌ها متوازن (Balanced) هستند یا خیر؟

ب) داده‌ها را به دو بخش آموزش و آزمون تقسیم کنید.

شرایط:

- نسبت داده‌های آموزش و آزمون: 80/20
- مقدار random_state=42

ج) یک مدل Logistic Regression برای تشخیص تراکنش‌های تقلبی آموزش دهید.

د) برای داده‌های آزمون:

- کلاس هر تراکنش را پیش‌بینی کنید.
- سعی کنید خروجی را در قالب جدول زیر یا پرینت ساده نمایش دهید.

Amount	TransactionCount	International	Actual	Predicted
--------	------------------	---------------	--------	-----------

ه) برای تراکنشی با مشخصات زیر، نتیجه را پیش‌بینی کنید:

Amount = 400

TransactionCount = 5

International = 1

هم موارد زیر را گزارش کنید:

- کلاس پیش‌بینی‌شده
- احتمال تقلبی بودن تراکنش

و) به پرسش‌های زیر پاسخ دهید.

1. اگر مبلغ تراکنش افزایش پیدا کند، آیا همیشه احتمال تقلبی بودن بیشتر می‌شود؟ چرا؟
2. چرا در مسائل تشخیص تقلب، داشتن احتمال پیش‌بینی مدل اهمیت زیادی دارد؟
3. اگر تعداد نمونه‌های تقلبی بسیار کمتر از نمونه‌های سالم باشد، چه مشکلی برای مدل ایجاد می‌شود؟

سؤال ۵ – تحلیل خروجی Logistic Regression

موضوع: ارزیابی مدل تشخیص تقلب بانکی

در این سؤال از مدل آموزش داده شده در سؤال قبل استفاده کنید.

الف) برای داده‌های آزمون موارد زیر را محاسبه کنید:

- Accuracy
- Confusion Matrix
- Classification Report

ب) ماتریس درهم‌ریختگی را رسم یا نمایش دهید.

سپس مشخص کنید:

- تعداد True Positive (TP)
- تعداد True Negative (TN)
- تعداد False Positive (FP)
- تعداد False Negative (FN)

ج) با استفاده از تابع:

```
predict_proba()
```

احتمال تعلق هر تراکنش به کلاس‌های 0 و 1 را محاسبه کنید.

خروجی را در قالب جدول زیر یا پرینت ساده نمایش دهید:

Transaction	Probability(No Fraud)	Probability(Fraud)
-------------	-----------------------	--------------------

د) به خروجی predict() و predict_proba() توجه کنید و پاسخ دهید:

1. تفاوت این دو تابع چیست؟
2. چرا در سیستم‌های تشخیص تقلب، احتمال مدل می‌تواند از کلاس نهایی مهم‌تر باشد؟
3. چرا بانک ممکن است بخواهد تراکنشی که احتمال تقلب آن 0.6 است را نیز بررسی کند؟

ه) فرض کنید خروجی predict_proba() برای چهار تراکنش به شکل زیر باشد:

Transaction	Fraud Probability
A	0.95
B	0.52
C	0.15
D	0.75

پاسخ دهید:

1. مدل برای هر تراکنش چه کلاسی پیش‌بینی می‌کند؟
2. کدام پیش‌بینی با اطمینان بیشتری انجام شده است؟
3. کدام تراکنش نزدیک مرز تصمیم‌گیری قرار دارد؟
4. اگر آستانه تصمیم‌گیری از 0.5 به 0.7 تغییر کند، کدام پیش‌بینی‌ها تغییر می‌کنند؟

(و) فرض کنید خروجی مدل روی داده‌های آزمون به شکل زیر باشد:

Accuracy = 95%

:Confusion Matrix

	Predicted	
	1	0
Actual 0	95	2
Actual 1	3	0

به پرسش‌های زیر پاسخ دهید:

1. آیا Accuracy بالا نشان‌دهنده عملکرد مناسب مدل است؟
2. مشکل اصلی مدل در تشخیص تراکنش‌های تقلبی چیست؟
3. چرا Recall برای کلاس Fraud اهمیت زیادی دارد؟
4. اگر هدف بانک جلوگیری از عبور تراکنش‌های تقلبی باشد، کدام خطا مهم‌تر است؟ False یا False Positive یا Negative؟ چرا؟

(ز) یکی از برنامه‌نویسان می‌گوید:

«مدل من Accuracy برابر 95٪ دارد، پس مدل کاملاً قابل اعتماد است.»

این جمله را نقد کنید و توضیح دهید:

- چرا Accuracy ممکن است در مسائل Fraud Detection گمراه‌کننده باشد؟
- Confusion Matrix چه اطلاعاتی را نشان می‌دهد که Accuracy نشان نمی‌دهد؟
- چرا Precision و Recall برای کلاس تقلب اهمیت زیادی دارند؟

سؤال ۶ – آموزش مدل KNN Regressor

در این سؤال قصد داریم با استفاده از الگوریتم **K-Nearest Neighbors Regressor**، قیمت خودروهای دست دوم را پیش‌بینی کنیم.

Dataset

```
import pandas as pd

car_data = pd.DataFrame({
    "Age": [ 1,1,2,2,2,3,3,4,4,5,5,6, 6,7,7,8,8,9,9,10,10,11,12,12, 13,14,15,16,17,18,19,20,21,22,
    23,24,25,26,27,28,29,30,31,32, 33,34,35,36 ],

    "Mileage": [ 10000,12000,15000,18000,22000,25000,30000,32000,
    38000,42000,47000,50000,55000,62000,65000,70000,
    75000,82000,87000,93000,98000,105000,115000,130000,
    135000,145000,155000,165000,175000,185000,195000,210000,
    220000,235000,250000,265000,280000,295000,310000,325000,
    340000,355000,370000,385000,400000,420000,440000,460000 ],

    "EngineSize": [ 1.2,1.2,1.4,1.4,1.4,1.6,1.6,1.6, 1.8,1.8,1.8,1.8,2.0,2.0,2.0,2.0,
    2.2,2.2,2.2,2.2,2.2,2.4,2.4,2.5,2.5, 2.5,2.7,2.7,2.8,2.8,3.0,3.0,3.0, 3.2,3.2,3.5,3.5,3.5,3.8,3.8,4.0,
    4.0,4.2,4.2,4.5,4.5,4.8,5.0,5.0 ],

    "Price": [ 23500,23000,22000,21500,21000,20000,19800,19000,
    18500,18000,17200,16800,16000,15500,15000,14500,
    13800,13200,12800,12300,11800,11200,10500,9800,
    9200,8600,8000,7500,7000,6500,6000,5500, 5000,4600,4200,3800,3500,3200,2900,2600,
    2400,2200,2000,1800,1600,1400,1200,1000 ]
})
```

هدف، پیش‌بینی ستون **Price** است.

الف) داده‌ها را بررسی کنید.

1. پنج سطر اول را نمایش دهید.
2. تعداد نمونه‌ها و ویژگی‌ها را مشخص کنید.
3. ویژگی‌ها (Features) و متغیر هدف (Target) را تعیین کنید.

ب) داده‌ها را به نسبت 80% آموزش و 20% آزمون تقسیم کنید.

از `random_state = 42` استفاده کنید.

ج) قبل از آموزش مدل، ویژگی‌ها را با استفاده از StandardScaler استانداردسازی کنید. سپس یک مدل KNeighborsRegressor با مقدار زیر آموزش دهید.

```
n_neighbors = 3
```

د) برای داده‌های آزمون قیمت خودروها را پیش‌بینی کنید.

جدولی مشابه جدول زیر ایجاد کنید.

Actual Price	Predicted Price
...	...

ه) برای خودروی زیر قیمت را پیش‌بینی کنید.

- Age = 4 سال
- Mileage = 45000
- EngineSize = 1.8

و) به پرسش‌های زیر پاسخ دهید.

1. چرا قبل از آموزش مدل، ویژگی‌ها را استانداردسازی کردید؟
2. اگر ویژگی Mileage بر حسب کیلومتر و ویژگی EngineSize بر حسب لیتر باشد، آیا بدون استانداردسازی فاصله‌ها به درستی محاسبه می‌شوند؟ توضیح دهید.
3. آیا KNN در مرحله آموزش واقعاً مدلی یاد می‌گیرد؟ دلیل خود را بیان کنید.

سؤال ۷ – تحلیل KNN Regressor و اثر مقدار K

در این سؤال از مدل آموزش داده شده در سؤال قبل استفاده کنید.

الف) معیارهای زیر را برای داده‌های آزمون محاسبه کنید.

- MAE
- MSE
- R^2

ب) مقدار K را برابر مقادیر زیر قرار دهید.

- $K = 1$
- $K = 3$
- $K = 5$
- $K = 7$
- $K = 9$

برای هر مقدار مدل را آموزش داده و مقدار R^2 را محاسبه کنید.

جدول زیر را کامل کنید.

K	MAE	MSE	R^2
1	...	...	...
3	...	...	...
5	...	...	...
7	...	...	...
9	...	...	...

ج) نموداری رسم کنید که در آن:

- محور افقی مقدار K
- محور عمودی مقدار R^2 باشد.

سپس به پرسش‌های زیر پاسخ دهید.

1. بهترین مقدار K کدام است؟
2. آیا افزایش K همیشه باعث افزایش دقت مدل می‌شود؟
3. اگر K بسیار بزرگ شود، مدل چه رفتاری خواهد داشت؟

د) فرض کنید دو مدل زیر آموزش داده شده‌اند.

مدل	R^2
Linear Regression	0.91
KNN Regressor	0.89

به پرسش‌های زیر پاسخ دهید.

1. آیا صرفاً با نگاه کردن به R^2 می‌توان بهترین مدل را انتخاب کرد؟
2. چه معیارهای دیگری را بررسی می‌کنید؟
3. در چه شرایطی ممکن است KNN عملکرد بهتری نسبت به Linear Regression داشته باشد؟

ه) به پرسش‌های مفهومی زیر پاسخ دهید.

1. چرا KNN را یک **Lazy Learning Algorithm** می‌نامند؟
2. تفاوت اصلی مرحله آموزش در KNN و Linear Regression چیست؟
3. اگر تعداد نمونه‌های Dataset ده برابر شود، انتظار دارید زمان پیش‌بینی KNN چگونه تغییر کند؟ چرا؟

و) فرض کنید یکی از همکلاسی‌های شما ویژگی‌ها را استانداردسازی نکرده است اما مدل را آموزش داده و مقدار $R^2 = 0.48$ به دست آورده است.

به نظر شما:

1. یکی از دلایل احتمالی این عملکرد ضعیف چیست؟
2. چگونه می‌توان این فرضیه را بررسی کرد؟
3. آیا همیشه استانداردسازی باعث بهبود عملکرد KNN می‌شود؟ توضیح دهید.

سؤال ۸ – آموزش مدل KNN Classification

در این سؤال قصد داریم با استفاده از KNN Classifier، وضعیت سلامت افراد را پیش‌بینی کنیم.

Dataset

```
import pandas as pd

health_data = pd.DataFrame({
    "BMI": [ 18,19,20,21,22,23,24,24,25,26,27,28,29,30,
            31,32,33,34,35,36,37,38,39,40,41,42,43,44, 20,22,23,25,27,28,30,32,34,36,38,40,42,44 ],
    "BloodPressure": [ 110,111,112,115,118,119,120,122,123,126,128,130,132,135,
                      138,140,142,143,145,148,150,152,154,157,160,162,164,166,
                      113,117,121,124,129,131,136,141,144,149,153,158,163,167 ],
    "HighRisk": [ 0,0,0,0,0,0,0,0,0,0,0, 1,1,1,1,1,1,1,1,1,1,1,1, 0,0,0,0,1,1,1,1,1,1,1,1 ]
})
```

هدف، پیش‌بینی ستون HighRisk است.

الف) ابتدا داده‌ها را بررسی کنید.

1. پنج سطر اول را نمایش دهید.
2. تعداد نمونه‌های هر کلاس را محاسبه کنید.
3. آیا داده‌ها متوازن هستند؟

ب) داده‌ها را به نسبت 80% آموزش و 20% آزمون تقسیم کنید.

از random_state=42 استفاده کنید.

ج) ویژگی‌ها را با استفاده از StandardScaler استانداردسازی کنید. سپس یک مدل KNeighborsClassifier با مقدار زیر آموزش دهید.

```
n_neighbors = 3
```

د) برای داده‌های آزمون:

1. کلاس هر نمونه را پیش‌بینی کنید.
2. Accuracy مدل را محاسبه کنید.

ه) جدولی مشابه جدول زیر ایجاد کنید.

Actual	Predicted
...	...

و) برای بیمار زیر پیش‌بینی انجام دهید.

- BMI = 28
 - BloodPressure = 130
- هم کلاس پیش‌بینی‌شده و هم احتمال تعلق به هر کلاس را گزارش کنید.

سؤال ۹ – تحلیل KNN Classification و اثر مقدار K

در این سؤال از مدل آموزش داده شده در سؤال قبل استفاده کنید.

الف) برای مقادیر زیر مدل را آموزش دهید.

K = 1

K = 3

K = 5

K = 7

K = 9

برای هر مقدار، معیارهای زیر را محاسبه کنید.

• Accuracy

• Precision

• Recall

• F1-score

جدول زیر را کامل کنید.

K	Accuracy	Precision	Recall	F1
1	...	...	...	...
3	...	...	...	...
5	...	...	...	...
7	...	...	...	...
9	...	...	...	...

ب) برای بهترین مقدار K، موارد زیر را نمایش دهید.

1. Confusion Matrix

2. Classification Report

سپس مشخص کنید.

• TP

• TN

• FP

• FN

ج) فرض کنید خروجی `predict_proba()` برای سه بیمار به صورت زیر باشد.

بیمار	احتمال سالم	احتمال پرخطر
A	0.49	0.51
B	0.05	0.95
C	0.52	0.48

به پرسش‌های زیر پاسخ دهید.

1. مدل هر بیمار را در کدام کلاس قرار می‌دهد؟
2. کدام بیمار نزدیک مرز تصمیم‌گیری قرار دارد؟
3. کدام پیش‌بینی از اطمینان بیشتری برخوردار است؟

د) نتایج مقادیر مختلف K را تحلیل کنید.

1. آیا بهترین مقدار K همان کوچک‌ترین مقدار بود؟ چرا؟
2. اگر K برابر تعداد کل نمونه‌ها باشد، مدل چگونه تصمیم‌گیری می‌کند؟
3. اگر K برابر ۱ باشد، مدل چه مزایا و چه معایبی خواهد داشت؟
4. چگونه می‌توان مقدار مناسب K را انتخاب کرد؟

ه) فرض کنید دو مدل زیر را آموزش داده‌ایم.

مدل	Accuracy
Logistic Regression	91%
KNN Classifier	91%

با وجود یکسان بودن Accuracy، آیا می‌توان نتیجه گرفت که عملکرد دو مدل کاملاً مشابه است؟