

تمرین ۱ – رگرسیون خطی برای پیش‌بینی اجاره‌بهای آپارتمان

یک وب‌سایت آگهی املاک می‌خواهد بر اساس مشخصات یک آپارتمان، اجاره‌بهای ماهانه آن (به هزار تومان) را تخمین بزند. دیتاست زیر شامل ۵۵ آپارتمان است.

```
import pandas as pd
apartment_data = pd.DataFrame({
    "area_sqm":
[44.5,132.5,89.8,125.4,157.2,102.3,97.6,44.0,68.6,97.5,119.9,135.5,82.6,43.2,71.0,148.7,61.7,91.5,
151.4,38.1,110.1,153.8,63.8,103.6,148.6,51.6,100.4,128.8,118.6,93.5,60.6,96.3,81.5,94.7,80.7,139.
7,131.1,74.2,106.6,69.5,91.6,79.1,117.2,81.3,92.4,124.9,86.6,148.3,57.6,127.6,87.8,88.3,114.3,100.
4,86.9],
    "rooms":
[1,1,2,4,2,2,1,4,3,3,1,1,2,1,4,4,4,1,1,4,1,3,3,3,4,4,4,2,3,4,4,2,1,1,4,2,1,3,3,2,3,2,1,4,4,2,3,4,2,1,1,2,2,
2,3],
    "distance_to_center_km":
[13.2,21.8,11.8,3.2,20.1,12.7,5.3,22.0,7.1,6.3,9.6,10.0,6.2,4.8,10.3,21.1,19.8,16.2,12.7,12.1,12.1,23.
6,18.6,1.5,19.1,13.1,4.9,10.1,23.5,5.7,20.4,10.4,14.9,5.1,20.4,14.7,11.4,20.1,13.8,10.8,1.0,17.3,12.5
,5.9,14.0,13.3,12.4,6.9,13.4,24.6,15.8,15.9,22.8,24.1,14.8],
    "building_age_years":
[10,27,28,8,33,25,28,7,15,0,18,0,9,34,5,21,16,11,32,5,28,29,31,7,28,14,13,19,13,24,3,7,32,33,11,27
,4,31,30,14,12,16,26,32,33,8,30,33,15,22,34,12,4,20,18],
    "rent_price_thousand_toman":
[1284,3486,2732,4601,4430,3150,2904,1571,2450,3329,3539,4137,2693,1310,2663,4535,1995,271
7,4415,1535,3124,4563,1872,3751,4547,1795,3579,3956,3533,3271,2172,3011,2084,2850,2656,40
88,3925,2072,3367,2227,3382,2322,3353,2796,3067,3921,2639,4860,1704,3363,2388,2556,3448,2
810,2702]
})
```

توضیح ستون‌ها:

ستون	توضیح
area_sqm	متراژ آپارتمان (متر مربع)
rooms	تعداد اتاق خواب
distance_to_center_km	فاصله تا مرکز شهر (کیلومتر)
building_age_years	سن ساختمان (سال)
rent_price_thousand_toman	اجاره‌بهای ماهانه – هدف Regression

بخش اول – Implement

الف) داده را با نسبت ۸۰٪ آموزش و ۲۰٪ آزمون تقسیم کنید ($\text{random_state}=42$).

ب) یک مدل `LinearRegression` با چهار ویژگی `area_sqm`، `rooms`، `distance_to_center_km` و `building_age_years` برای پیش‌بینی `rent_price_thousand_toman` آموزش دهید.

ج) روی داده آزمون، MAE ، MSE و R^2 را محاسبه کنید.

د) نمودار `Predicted` در مقابل `Actual` را همراه با خط ایده‌آل ($x = y$) رسم کنید.

ه) ضرایب مدل (`_coef`) را به همراه نام هر ویژگی چاپ کنید.

بخش دوم – Observe

جدول معیارها و جدول ضرایب را از خروجی کد پر کنید.

بخش سوم – Reason

الف) کدام ویژگی بیشترین تأثیر مثبت و کدام بیشترین تأثیر منفی را روی اجاره‌بها دارد؟ آیا این نتیجه با شهود شما هم‌خوانی دارد؟

ب) اگر ویژگی `distance_to_center_km` را حذف کنیم، انتظار دارید R^2 افزایش یابد، کاهش یابد یا تغییر محسوسی نکند؟ دلیل خود را بر اساس ضریب به‌دست‌آمده توضیح دهید.

ج) فرض کنید مدیر سایت می‌گوید «چون MAE ما فقط ۲۰۰ هزار تومان است، پس مدل برای همه آپارتمان‌ها دقیق است.» این ادعا را نقد کنید – MAE پایین دقیقاً چه چیزی را تضمین می‌کند و چه چیزی را تضمین نمی‌کند؟

تمرین ۲ – Logistic Regression برای پیش‌بینی ریزش مشتری اپراتور موبایل

یک اپراتور تلفن همراه می‌خواهد پیش از آنکه مشتری خط خود را قطع کند (Churn)، آن را شناسایی کند. دیتاست زیر رفتار ۸۵ مشترک را نشان می‌دهد. توجه کنید این داده نامتوازن است.

```
import pandas as pd
telecom_data = pd.DataFrame({
    "tenure_months":
[25,4,57,1,22,20,42,11,22,39,21,45,40,15,27,23,67,3,64,61,2,52,70,30,25,63,8,44,34,49,38,21,50,22,
29,55,1,65,19,64,38,57,57,38,47,34,2,17,33,17,19,56,14,38,31,49,62,34,53,3,29,37,45,49,60,55,22,
57,40,30,33,49,10,34,61,56,12,11,69,45,45,20,17,40,51],
    "monthly_usage_min":
[175.2,138.5,98.1,120.8,451.6,166.5,762.6,551.7,442.0,571.6,225.8,742.8,674.6,586.5,394.6,676.8,
600.9,535.1,732.9,514.3,305.4,451.2,173.2,169.8,586.0,632.3,778.2,683.8,444.0,90.0,401.3,743.8,6
34.3,398.4,375.1,190.0,158.2,77.4,716.1,519.3,131.8,343.0,58.3,183.3,590.0,527.9,393.6,234.3,528
.7,766.0,359.7,74.7,65.0,84.6,768.6,441.8,673.2,152.6,223.1,559.7,718.5,285.7,70.4,694.0,246.9,59
8.0,143.3,562.1,676.3,587.2,300.1,586.8,128.8,264.8,347.3,704.2,139.9,706.5,643.2,777.9,306.8,17
9.9,207.6,665.7,772.9],
    "data_usage_gb":
[28.1,19.6,11.8,33.4,35.0,4.1,9.0,33.4,34.0,12.9,11.5,17.5,21.8,4.3,33.6,21.6,31.1,9.6,38.6,30.2,14.1
,38.0,28.2,33.7,2.3,2.7,29.8,12.5,20.9,6.7,39.1,20.4,33.2,3.4,19.4,3.0,35.4,18.1,3.2,3.5,21.8,3.5,7.8,
17.7,20.2,23.5,25.0,15.2,24.9,6.7,11.4,32.0,6.5,9.3,10.1,19.4,0.5,1.7,18.7,6.9,27.3,31.9,23.3,27.9,15
.9,2.3,17.9,15.2,24.1,5.8,9.5,32.7,10.9,16.7,37.5,11.4,6.2,28.2,22.9,24.7,2.2,17.0,0.7,10.2,28.4],
    "complaints_count":
[0,0,3,1,1,1,2,1,1,3,0,1,0,1,1,1,0,4,3,0,1,1,0,1,3,1,1,2,2,1,0,0,0,0,1,2,1,1,0,2,2,0,1,2,2,1,1,2,0,0,0,2,1,
2,1,2,0,0,0,1,1,2,0,0,1,0,1,1,2,1,2,0,0,1,1,1,2,1,1,4,2,0,1,0,0],
    "churned":
[0,0,1,1,0,0,0,1,0,0,0,0,0,0,0,0,1,0,0,1,0,0,0,0,1,0,0,0,0,0,0,0,0,0,1,0,0,0,0,0,0,0,0,0,0,0,1,0,0,0,0,1,
1,0,0,0,0,0,0,0,0,0,0,0,0,1,1,0,0,0,0,0,0,0,0,0,1,0,0,0,0,0,1,0,0]
})
```

توضیح ستون‌ها:

توضیح	ستون
مدت زمان اشتراک مشترک (ماه)	tenure_months
دقایق مکالمه در ماه	monthly_usage_min
مصرف اینترنت ماهانه (گیگابایت)	data_usage_gb
تعداد تماس‌های شکایت ثبت‌شده	complaints_count
متغیر هدف – آیا خط را قطع کرده؟ (۱ = بله، ۰ = خیر)	churned

بخش اول – Implement

- الف) پنج سطر اول را نمایش دهید. تعداد و درصد هر کلاس در ستون churned را محاسبه کنید.
- ب) داده را با نسبت ۸۰٪/۲۰٪ و با `random_state=42` و `stratify=y` تقسیم کنید.
- ج) ویژگی‌ها را با `StandardScaler` استاندارد کنید و یک `LogisticRegression` آموزش دهید.
- د) روی داده آزمون، `Accuracy`، `Precision`، `Recall` و `F1-score` را محاسبه کنید و `Confusion Matrix` را نمایش دهید.

بخش دوم – Observe

جدول معیارها و جدول TP/TN/FP/FN را پر کنید.

بخش سوم – Reason

- الف) با توجه به درصد کلاس‌ها، اگر یک مدل ساختگی همیشه «قطع نکرده» (۰) را پیش‌بینی کند، `Accuracy` آن تقریباً چند درصد خواهد بود؟ (بدون اجرای کد استدلال کنید).
- ب) در این مسئله، از دست دادن یک مشتری که واقعاً در حال ریزش است (FN) در مقابل تماس تبلیغاتی اشتباه با مشترک وفادار (FP)، کدام هزینه بیشتری برای اپراتور دارد؟ بر این اساس کدام معیار – `Precision` یا `Recall` – اهمیت بیشتری دارد؟
- ج) `predict_proba` مدل را استخراج کنید. اگر آستانه تصمیم‌گیری را از ۰.۵ به ۰.۳ کاهش دهیم، انتظار دارید `Precision` و `Recall` چگونه تغییر کنند؟ با اجرای مدل با `threshold=0.3` پاسخ خود را تأیید کنید.

تمرین ۳ – KNN Regressor برای پیش‌بینی زمان تحویل سفارش غذا

یک اپلیکیشن سفارش غذا می‌خواهد زمان تقریبی تحویل سفارش (به دقیقه) را بر اساس فاصله، تعداد اقلام سفارش و شدت ترافیک پیش‌بینی کند. دیتاست زیر شامل ۵۵ سفارش است.

```
import pandas as pd
delivery_data = pd.DataFrame({
    "distance_km":
[7.9,9.7,4.6,2.0,11.5,1.7,11.8,9.5,8.8,3.5,5.1,4.8,9.6,7.5,6.6,8.9,12.6,1.4,11.1,4.9,3.8,7.9,3.1,10.7,5.0,
5.0,14.5,5.0,2.2,1.6,11.0,3.7,6.3,12.1,12.7,3.7,6.8,11.6,6.6,11.6,8.4,12.5,6.5,8.9,13.6,5.4,10.4,4.6,7.
3,6.0,3.0,12.1,12.9,4.8,11.1],
    "num_items":
[6,2,5,2,6,9,1,8,1,1,9,7,4,5,5,7,6,5,7,8,7,6,5,2,9,1,11,11,6,2,8,2,10,11,5,4,1,7,9,1,6,8,1,6,8,1,1,11,3,1
0,10,3,2,5,3],
    "traffic_level":
[1,3,2,1,3,1,1,2,5,3,3,2,4,3,2,4,1,4,3,1,4,2,4,2,1,1,4,5,3,5,3,1,3,1,5,5,1,3,2,3,4,1,2,1,5,5,1,5,1,3,4,2,3,
5,4],
    "delivery_time_min":
[63.7,63.5,46.2,24.1,85.7,33.0,68.0,73.2,72.0,42.8,63.1,45.1,79.6,64.7,62.6,86.1,70.7,41.3,83.3,49.7,
59.2,62.8,59.6,64.1,51.2,41.2,107.7,78.3,49.2,46.4,83.2,37.9,64.7,86.3,96.9,63.1,42.7,86.6,64.7,73.
2,73.9,77.6,56.2,57.3,110.2,66.3,58.0,76.2,55.8,63.5,55.7,75.3,81.2,73.7,88.0]
})
```

توضیح ستون‌ها:

ستون	توضیح
distance_km	فاصله رستوران تا مقصد (کیلومتر)
num_items	تعداد اقلام سفارش داده شده
traffic_level	شدت ترافیک در لحظه سفارش (۱ = خلوت تا ۵ = بسیار سنگین)
delivery_time_min	زمان واقعی تحویل (دقیقه) – هدف Regression

بخش اول – Implement

الف) داده را با نسبت ۸۰٪/۲۰٪ تقسیم کنید (random_state=42).

ب) ویژگی‌ها را با StandardScaler استاندارد کنید (دقت کنید مقیاس distance_km و traffic_level متفاوت است) و یک KNeighborsRegressor با n_neighbors=5 آموزش دهید.

ج) روی داده آزمون، MSE، MAE، و R^2 را محاسبه کنید.

د) مدل را برای K برابر با ۱، ۳، ۵، ۷، ۹ و ۱۵ دوباره آموزش دهید و R^2 هرکدام را ثبت کنید. (ه) برای سفارشی با num_items=4، distance_km=6، traffic_level=3، زمان تحویل را با بهترین مقدار K پیش‌بینی کنید.

بخش دوم – Observe

جدول K و R^2 را پر کنید.

بخش سوم – Reason

الف) بهترین مقدار K کدام است؟ آیا رابطه بین K و R^2 یکنواخت است یا یک نقطه بهینه دارد؟

ب) اگر هم‌کلاسی شما فراموش کند ویژگی‌ها را استاندارد کند و مستقیماً distance_km (بازه تقریبی ۱ تا ۱۵) و num_items (بازه ۱ تا ۱۱) را در KNN استفاده کند، چرا فاصله اقلیدسی عملاً تحت تأثیر یک ویژگی خاص قرار می‌گیرد؟

ج) چرا KNN را یک الگوریتم Lazy Learning می‌نامند؟ اگر تعداد سفارش‌های دیتاست ده برابر شود، این ویژگی چه تأثیری روی زمان پیش‌بینی (نه آموزش) دارد؟

تمرین ۴ – خوشه‌بندی کاربران اپلیکیشن فیتنس با K-Means

یک اپلیکیشن سلامت می‌خواهد بدون هیچ برچسب از پیش تعیین‌شده‌ای، کاربران خود را بر اساس رفتار روزانه‌شان به گروه‌های رفتاری مشابه تقسیم کند. دیتاست زیر شامل ۴۸ کاربر با دو ویژگی است.

```
import pandas as pd
fitness_data = pd.DataFrame({
    "daily_steps":
[1279,2424,9944,7489,14911,5827,7794,3039,9548,17235,5520,14444,3787,16060,9714,3138,143
05,16088,3466,2996,5273,9754,17151,15630,6518,1633,11127,10770,5106,11260,17687,3454,635
1,15414,3705,3189,3924,14084,3166,2549,11658,14036,13857,8362,16582,3564,8505,7277],
    "calories_burned":
[723,352,304,1182,467,674,1112,467,534,741,221,174,814,539,233,450,878,947,680,381,1031,368
,944,310,1131,962,676,605,751,844,735,880,242,588,941,610,1169,710,476,1086,593,723,823,104
8,369,1067,752,534]
})
```

توضیح ستون‌ها:

ستون	توضیح
daily_steps	تعداد قدم‌های روزانه کاربر
calories_burned	کالری سوزانده شده روزانه

توجه: این دیتاست هیچ ستون برچسبی (Target) ندارد.

بخش اول – Implement

الف) پنج سطر اول را نمایش دهید و تعداد کل نمونه‌ها را مشخص کنید.

ب) ویژگی‌ها را با StandardScaler استاندارد کنید.

ج) یک مدل KMeans با n_clusters=3 و random_state=42 آموزش دهید.

د) برچسب خوشه هر کاربر را به دیتاست اضافه کنید و نمودار پراکندگی رسم کنید که رنگ هر نقطه بر اساس شماره خوشه‌اش باشد؛ مراکز خوشه‌ها (Centroids) را نیز روی همان نمودار نمایش دهید.

ه) میانگین daily_steps و calories_burned را برای هر خوشه (روی داده اصلی غیر استاندارد) محاسبه و گزارش کنید.

بخش دوم – Observe

جدول شماره خوشه، میانگین‌ها و تعداد اعضا را پر کنید.

بخش سوم – Reason

الف) به هر یک از سه خوشه یک نام معنادار بدهید (مثلاً «کم‌تحرک»، «متوسط»، «پرتحرک») بر اساس میانگین‌های واقعی مدل خودتان.

ب) آیا شماره خوشه (۰، ۱ یا ۲) نشان‌دهنده ترتیب یا کیفیت خوشه‌هاست؟ چرا اگر مدل را دوباره اجرا کنید ممکن است شماره‌ها جابه‌جا شوند؟

ج) چرا برای سنجش کیفیت این خوشه‌بندی نمی‌توان از Accuracy یا F1-score استفاده کرد؟ این را با تمرین جدید ۲ (که در آن Precision/Recall استفاده کردید) مقایسه کنید.

د) مدل را یک‌بار با $n_clusters=2$ و یک‌بار با $n_clusters=6$ اجرا کنید. آیا افزایش تعداد خوشه‌ها همیشه به معنای خوشه‌بندی «بهتر» است؟ اگر $n_clusters$ را برابر ۴۸ (تعداد کل نمونه‌ها) قرار دهیم چه اتفاقی می‌افتد و چرا بی‌فایده است؟