

شروع مطالعه مقاله برای شما که دارید حرفه‌ای می‌شوید...

تا اینجا با مفاهیم مهمی مانند Gradient, Backpropagation, Learning Rate, Momentum و Adam آشنا شدیم.

حالا می‌خواهیم ببینیم این مفاهیم در یک مقاله علمی واقعی چگونه توضیح داده می‌شوند و چگونه به یکدیگر مرتبط‌اند.

هدف از مطالعه مقاله، حفظ کردن فرمول‌ها نیست؛ بلکه درک عمیق‌تر مفاهیم و تقویت مهارت خواندن متون علمی است.

برای هر سؤال، بخش مرتبط مقاله مشخص شده تا بدانید دقیقاً کدام قسمت را باید مطالعه کنید.

سعی کنید مطالب را بفهمید، با آموخته‌های کلاس ارتباط دهید و پاسخ‌ها را با بیان خودتان توضیح دهید.

لینک مقاله: برای دانلود مقاله اینجا [کلیک](#) کنید.

راهنمای پاسخ‌گویی

پاسخ‌ها باید تشریحی و با بیان خودتان باشند. صرفاً کپی‌کردن تعریف‌ها یا روابط مقاله کافی نیست. در سؤال‌های محاسباتی، علاوه بر نتیجه، تفسیر نتیجه نیز بخشی از پاسخ است.

سؤال ۱ — گرادیان دقیقاً چه چیزی به ما می‌گوید؟

زمان پیشنهادی: ۲۰ دقیقه

فرض کنید Loss یک شبکه عصبی به تعداد زیادی پارامتر وابسته است و در وضعیت فعلی شبکه، Gradient آن محاسبه شده است.

الف) توضیح دهید Gradient چه اطلاعاتی درباره تغییر Loss نسبت به پارامترهای مدل در اختیار ما قرار می‌دهد و چرا این اطلاعات را باید محلی (local) در نظر گرفت.

ب) تفاوت جهت Gradient و اندازه Gradient را توضیح دهید. همچنین توضیح دهید مثبت، منفی یا نزدیک صفر بودن Gradient درباره رفتار محلی Loss چه اطلاعاتی به ما می‌دهد.

ج) چرا برای کاهش Loss در جهت منفی Gradient حرکت می‌کنیم؟

د) دانشجویی می‌گوید: «اگر Gradient یک پارامتر بزرگ‌تر باشد، یعنی آن پارامتر برای شبکه مهم‌تر است.» این برداشت را نقد کنید. Gradient بزرگ واقعاً چه چیزی را نشان می‌دهد؟

ه) توضیح دهید چرا Gradient با Parameter Update یکسان نیست و Learning Rate چگونه این دو را به یکدیگر مرتبط می‌کند.

محل مطالعه در مقاله: **Section ۲.۱ — Gradient Descent**؛ به‌ویژه روابط **Gradient Descent** و توضیحات پیرامون **gradient** و **rate learning / size step**.

سؤال ۲ — یک **Gradient** ثابت، سه **Learning Rate** متفاوت

زمان پیشنهادی: ۲۰ دقیقه

رابطه زیر را در نظر بگیرید:

$$W(t+1) = W(t) - \eta \nabla L$$

فرض کنید در یک مرحله از آموزش Gradient کاملاً درست محاسبه شده است.

الف) توضیح دهید η چه نقشی در این رابطه دارد و چرا تغییر Learning Rate، با ثابت بودن Gradient، می‌تواند رفتار آموزش را کاملاً تغییر دهد.

ب) رفتار training را در سه حالت Learning Rate بسیار کوچک، مناسب و بسیار بزرگ تحلیل کنید. در هر حالت درباره اندازه update، سرعت پیشرفت، overshooting و stability صحبت کنید.

ج) آیا جمله «هرچه Learning Rate بزرگ‌تر باشد، مدل سریع‌تر یاد می‌گیرد» درست است؟ با استدلال پاسخ دهید.

د) چرا ممکن است در ابتدای training استفاده از گام‌های بزرگ‌تر مفید باشد ولی در مراحل بعد به گام‌های کوچک‌تر نیاز داشته باشیم؟

ه) این موضوع چه انگیزه‌ای برای Learning Rate Scheduling ایجاد می‌کند؟

محل مطالعه در مقاله: **Section ۲.۱ — Gradient Descent** برای مفهوم **Learning Rate**. بخش‌های مربوط به **step-size selection** برای مطالعه تکمیلی مفیدند.

سؤال ۳ — **Backpropagation** وزن‌ها را تغییر نمی‌دهد

زمان پیشنهادی: ۲۵ دقیقه

یک شبکه عصبی چندلایه را در نظر بگیرید. یک weight در لایه ابتدایی مستقیماً به Loss متصل نیست و اثر آن از چندین محاسبه میانی عبور می‌کند.

الف) توضیح دهید چرا برای محاسبه $\partial L / \partial w$ در چنین شبکه‌ای به Chain Rule نیاز داریم.

ب) Backpropagation چگونه از Chain Rule برای محاسبه Gradient از Loss به سمت لایه‌های قبلی استفاده می‌کند؟

ج) منظور از «Backward» در Backpropagation چیست و در این مرحله چه کمیت‌هایی از لایه‌های انتهایی به سمت لایه‌های ابتدایی محاسبه می‌شوند؟

د) جمله «Backpropagation» وزن‌های شبکه را تغییر می‌دهد تا Loss کمتر شود» را بررسی کنید. اشکال این جمله چیست؟

ه) تفاوت وظیفه این سه مرحله را توضیح دهید: Forward Pass → Backpropagation → Optimizer / Parameter Update

و) اگر Gradient Backpropagation‌ها را به‌درستی محاسبه کند، آیا این موضوع به‌تنهایی تضمین می‌کند که parameter update مناسبی خواهیم داشت؟ نقش Learning Rate و optimizer را در پاسخ وارد کنید.

محل مطالعه در مقاله: **Section ۳ — Backpropagation**؛ به‌خصوص توضیحات مربوط به **feed-forward network** و استفاده از **Chain Rule**.

سؤال ۴ — از محاسبه **Gradient** تا تفسیر آن

زمان پیشنهادی: ۲۵ دقیقه

یک نوروں ساده داریم:

$$\hat{y} = \mathbf{w}\mathbf{x} + \mathbf{b} \quad L = (\hat{y} - y)^2$$

فرض کنید: $x = 2$ ، $w = 3$ ، $b = 1$ ، $y = 10$

الف) ابتدا $\hat{y}$ و Loss را محاسبه کنید.

ب) با استفاده از Chain Rule، $\partial L / \partial w$ را مرحله‌به‌مرحله محاسبه کنید. مسیر وابستگی $w \rightarrow \hat{y} \rightarrow L$ باید در پاسخ مشخص باشد.

ج) علامت Gradient به‌دست‌آمده را تفسیر کنید. این علامت درباره اثر افزایش جزئی w بر Loss چه می‌گوید؟

د) اگر $\eta = 0.01$ باشد، یک مرحله Gradient Descent روی w انجام دهید.

ه) بدون محاسبات طولانی پیش‌بینی کنید اگر به‌جای 0.01 مقدار $\eta = 0.1$ استفاده شود، اندازه update چه تغییری می‌کند. آیا جهت update نیز تغییر می‌کند؟ چرا؟

و) این مثال چگونه تفاوت میان Gradient و Learning Rate را نشان می‌دهد؟

محل مطالعه در مقاله: **Section ۳ — Backpropagation Chain Rule** و محاسبه **gradients**، همراه با **Section ۲.۱ — Gradient Descent** برای **parameter update**.

سؤال ۵ — چرا **Momentum** به وجود آمد؟

زمان پیشنهادی: ۲۵ دقیقه

فرض کنید سطح تابع **Loss** دارای یک ناحیه باریک و کشیده (**ravine**) است. در چنین شرایطی **Gradient Descent** یا **SGD** ممکن است هنگام حرکت به سمت **minimum**، بین دو سمت این ناحیه نوسان کند و مسیر زیگزاگی ایجاد شود.

(الف) توضیح دهید چرا استفاده از فقط **Gradient** فعلی می تواند باعث چنین **oscillation** هایی شود.

(ب) **Momentum** چه اطلاعاتی را علاوه بر **Gradient** فعلی نگه می دارد؟

(ج) مفهوم **memory/history** در **Momentum** را توضیح دهید.

(د) چگونه این **history** می تواند حرکت هایی را که در چند مرحله جهت نسبتاً ثابتی داشته اند تقویت کند؟

(ه) چگونه همین سازوکار می تواند **oscillation** های غیرضروری را کاهش دهد؟

(و) جمله «**Momentum** همان **SGD** است، فقط با **Learning Rate** بزرگ تر» را ارزیابی کنید. چرا این توصیف تفاوت اصلی این دو روش را نشان نمی دهد؟

(ز) با استفاده از **Figure** مربوط به **Momentum** در مقاله، تفاوت مسیر **Gradient Descent** با و بدون **Momentum** را با زبان خود توضیح دهید.

محل مطالعه در مقاله: **Section ۲.۴ — Momentum**؛ به ویژه رابطه **Momentum** و **Figure ۲: momentum with and without descent Gradient**.

سؤال ۶ — **Adam** چه چیزی به **Momentum** اضافه می کند؟

زمان پیشنهادی: ۳۰ دقیقه

Adam دو کمیت اصلی را از **Gradient** های گذشته نگه می دارد: m_t و v_t . هدف این سؤال حفظ کردن فرمول ها نیست؛ معنای این دو کمیت را توضیح دهید.

(الف) m_t چه اطلاعاتی درباره **Gradient** های اخیر نگه می دارد؟ چرا این بخش **Adam** از نظر شهودی به **Momentum** شباهت دارد؟

(ب) v_t چه اطلاعات متفاوتی نگه می دارد؟

ج) چرا استفاده از g_t^2 برای تخمین scale یا magnitude گرادیان مناسب است؟ در پاسخ به اثر مربع کردن بر علامت Gradient توجه کنید.

د) با بیان خودتان توضیح دهید m_t چگونه اطلاعات مربوط به جهت و تاریخچه Gradient ها را خلاصه می کند و v_t چگونه اطلاعات مربوط به اندازه یا scale آن ها را در اختیار Adam قرار می دهد.

هـ) توضیح دهید چرا داشتن هر دو نوع اطلاعات باعث می شود Adam بتواند effective step size را تطبیقی تر تنظیم کند.

و) اگر Adam فقط m_t داشت ولی v_t را نداشت، از نظر مفهومی به کدام optimizer نزدیک تر می شد؟ دلیل بیاورید.

ز) عبارت «adaptive scaling + gradient history = Adam» را با زبان خود توضیح دهید.

محل مطالعه در مقاله: **Section ۶ — Adaptive Learning Rate Methods** و به طور خاص **Section**

۶.۳ — Optimizer Adam؛ قسمت **first moment**، **second moment** و **rule update**.

سؤال ۷ — سؤال تلفیقی: از **Loss تا Adam**

زمان پیشنهادی: ۳۵ دقیقه

فرض کنید یک شبکه عصبی پیش بینی نامناسبی تولید کرده و مقدار Loss بالا است. فرایند آموزش را از محاسبه Loss تا تغییر پارامترهای مدل، به صورت یک زنجیره منطقی و پیوسته توضیح دهید.

پاسخ شما باید حداقل این مسیر را به ترتیب منطقی به هم مرتبط کند:

Prediction → Loss → Backpropagation → Gradient → Optimizer → Parameter Update

الف) Gradient در این زنجیره چه اطلاعاتی فراهم می کند؟

ب) Backpropagation چگونه این Gradient ها را به دست می آورد؟

ج) چرا جهت منفی Gradient برای minimization اهمیت دارد؟

د) Learning Rate در کجای این زنجیره وارد می شود و چه چیزی را کنترل می کند؟

هـ) اگر optimizer، SGD باشد، تصمیم update عمدتاً بر چه اطلاعاتی استوار است؟

و) Momentum چه نوع memory به این فرایند اضافه می کند و چرا؟

ز) Adam چه اطلاعات دیگری علاوه بر history در نظر می گیرد؟

ح) توضیح دهید چرا Backpropagation، optimizer و Learning Rate سه نقش متفاوت در فرایند آموزش دارند و نباید با یکدیگر اشتباه شوند.

در پایان، در یک پاراگراف کوتاه مسیر SGD → Momentum → Adam را با بیان خودتان توضیح دهید؛
به گونه‌ای که مشخص شود هر روش نسبت به روش قبلی چه ایده‌ای به optimization اضافه کرده است.

محل مطالعه در مقاله: **Section ۲.۱ — Gradient Descent** — **Section ۲.۴ — Momentum**
Section ۳ — Backpropagation — **Section ۴ — Stochastic Gradient Descent** و ۶.۳ —
Optimizer Adam / Adaptive Learning Rate Methods