



تمرینات کلاسی - هفته پانزدهم – 1

در پایان Classwork باید بتوانید با زبان خودتان توضیح دهید:

تفاوت zero-shot وfew-shot

فرق few-shot باfine-tuning ،

اهمیت انتخابexamples ،

نقش متفاوت stop وmax_tokens ،

کاربرد logprobs برایuncertainty ،

محدودیتconfidence ، و ایده‌ی human review برای نمونه‌های نامطمئن.

این دو تا سلول رو در ابتدا اجرا کنید. (راحت‌تره که نتبوک همراه با این فایل رو دانلود کنید اگه دوست داشتید)

```
from getpass import getpass
from openai import OpenAI
OPENROUTER_API_KEY = getpass("Enter your OpenRouter API key: ")
client = OpenAI(
    base_url="https://openrouter.ai/api/v1",
    api_key=OPENROUTER_API_KEY
)
MODEL = "meta-llama/llama-3.1-8b-instruct"
```

9

```
def complete(prompt, model=MODEL, **kwargs):
    params = {
        "max_tokens": 40,
        "temperature": 0,
        **kwargs
    }
    response = client.completions.create(
        model=model,
        prompt=prompt,
        **params
    )
    return response.choices[0].text
```

تمرین 1 – Predict → Run → Explain

چهار prompt زیر را با Completion API اجرا کنید. در همه‌ی اجراها از temperature = 0 استفاده کنید. اما قبل از اجرای هر prompt، ابتدا بنویسید انتظار دارید مدل چه نوع پاسخی تولید کند.

Prompt A

```
The largest planet in the solar system is
```

Prompt B

```
Question: Which planet is known as the Red Planet?
Answer:
```

Prompt C

```
Question: What is the largest ocean on Earth?
Answer: Pacific Ocean

Question: What is the tallest mountain in the world?
Answer: Mount Everest

Question: What is the capital of Brazil?
Answer:
```

Prompt D

```
Question: What is the largest ocean on Earth?
Question: What is the tallest mountain in the world?
Question: What is the capital of Brazil?
```

سؤال‌ها

1. قبل از اجرا، چهار prompt را از نظر واضح بودن کاری که مدل باید انجام دهد رتبه‌بندی کنید.
2. برای هرprompt ، پیش‌بینی شما چه بود؟ مدل واقعاً چه تولید کرد؟ آیا نتیجه با انتظار شما یکسان بود؟
3. Prompt C و D تقریباً درباره‌ی موضوعات مشابهی صحبت می‌کنند. چه تفاوتی در ساختار document آن‌ها وجود دارد؟
4. آیا مدل در Prompt D ادامه‌ی الگوی سؤال‌ها را تولید کرد یا شروع به پاسخ‌دادن کرد؟
5. اگر رفتار واقعی مدل با مثال GPT-3 در اسلایدهای استاد() متفاوت بود، چه توضیحی برای آن دارید؟

6. آیا instruction-tuned بودن مدل با این اصل که LLM همچنان next token را پیش‌بینی می‌کند تناقض دارد؟ در حداکثر سه جمله توضیح دهید.

تمرین 2 – Few-shot Classification Lab

پیام‌های پشتیبانی را در یکی از چهار دسته‌ی زیر قرار دهید:

```
billing
technical
account
shipping
```

Test Set

```
1. I was charged again after I had already cancelled my subscription.

2. The password reset link opens a blank page.

3. Tracking says delivered, but I never received the package.

4. I changed my email address and now I can't sign in.
```

ابتدا بدون مدل، برای هر چهار مورد با هم‌گروهی‌ها یک label مرجع انتخاب کنید. اگر درباره‌ی نمونه‌ای اختلاف نظر دارید، آن را ثبت کنید.

مرحله A – Zero-shot

بدون هیچ example ، فقط instruction بدهید:

```
Classify the support ticket into exactly one of these categories:

billing
technical
account
shipping

Return only the category name.
```

```
Ticket:
I was charged again after I had already cancelled my subscription.

Category:
```

Sample	Prediction	Match?
1		
2		
3		
4		

مرحله Few-shot set A – B

```
Ticket: My payment was declined.
Category: billing

Ticket: The application crashes whenever I upload a file.
Category: technical

Ticket: I forgot my password and cannot log in.
Category: account

Ticket: My parcel is several days late.
Category: shipping
```

دوباره هر چهار test sample را اجرا کنید.

مرحله Few-shot set B - C

```
Ticket: I cancelled my subscription but I was billed again.
Category: billing

Ticket: The password reset page does not load.
Category: technical

Ticket: I updated my email address and now I cannot access my account.
```

Category: account

Ticket: Tracking says delivered, but there is no package here.
Category: shipping

باز هم همان test set را اجرا کنید.

Sample	Zero-shot	Few-shot A	Few-shot B
1			
2			
3			
4			

1. آیا few-shot در همه‌ی نمونه‌ها بهتر از zero-shot بود؟
2. Few-shot A و Few-shot B هر دو چهار example دارند. آیا رفتار مدل در آن‌ها یکسان بود؟
3. اگر یکی بهتر بود، چه ویژگی examples ممکن است باعث این تفاوت شده باشد؟
4. درباره‌ی جمله‌ی «در few-shot فقط تعدادexample ها مهم است» چه نتیجه‌ای می‌گیرید؟
5. در این آزمایش آیا weights مدل تغییر کردند؟
6. اگر weights تغییر نکردند، اطلاعات مربوط به task و format از کجا وارد مدل شدند؟

تمرین ۳ – کنترل خروجی مدل

تمرکز اصلی این تمرین روی کنترل شکل output است، نه اندازه‌گیری accuracy .

```
I was billed twice for the same order.

The application closes immediately after I open it.

My package has still not arrived after two weeks.
```

بخش A - Bare Prompt در برابر Instruction

```
Ticket: I was billed twice for the same order.
Category:
```

سپس prompt را واضح‌تر کنید:

```
Classify the ticket into exactly one of:

billing
technical
account
shipping

Return only the category name and nothing else.

Ticket: I was billed twice for the same order.
Category:
```

1. آیا instruction باعث شد خروجی از نظر format قابل‌پیش‌بینی‌تر شود؟
2. اگر مدل بنویسد «The correct category is billing because the user was charged twice.» آیا classificationاشتباه است، format اشتباه است، یا هر دو؟
3. اگر instruction-only روی مدل فعلی تقریباً همیشه خروجی خوبی بدهد، آیا این یعنی few-shot دیگر هیچ کاربردی ندارد؟ چه نتیجه‌ای می‌توانیم بگیریم و چه نتیجه‌ای نمی‌توانیم بگیریم؟

بخش B – Stop Sequences

```
Ticket: The app crashes when I upload an image.
Category: technical

Ticket: I cannot access my profile.
Category: account

Ticket: My parcel did not arrive.
Category: shipping

Ticket: I was charged twice for the same order.
Category:
```

یک بار بدون stop اجرا کنید. سپس جداگانه این سه حالت را آزمایش کنید:

```
stop=["\n"]
stop=["Ticket:"]
stop=["."]
```

1. خروجی در هر سه حالت چه تفاوتی داشت؟
2. برای ساختار فعلیprompt ، کدام stop مناسب‌تر بود؟
3. چرا "\n" ممکن است انتخاب خوبی باشد؟
4. چرا "." ممکن است در بعضی task ها stop بدی باشد؟
5. آیا stop به مدل می‌گوید چه چیزی تولید کند یا فقط تعیین می‌کند تولید چه زمانی متوقف شود؟

بخش C – max_tokens

labelها را موقتاً به این صورت تغییر دهید:

```
billing issue
technical issue
account issue
shipping issue
```

یک sample را ابتدا با max_tokens=1 و سپس با مقدار بزرگ‌تر اجرا کنید.

1. آیا max_tokens=1 توانست label کامل را تولید کند؟
2. چرا «یک token الزاماً به معنی «یک کلمه» یا «یک «label نیست؟
3. تفاوت نقش max_tokens و stop چیست؟

تمرین ۴ - Logprobs و Uncertainty

فرض کنید یک تیم پشتیبانی می‌خواهد پیام‌ها را به دو گروه تقسیم کند:

```
A = urgent
B = routine
```

Few-shot examples

```
Message: The production website is completely down and customers cannot place orders.
Label: A

Message: Please send me the meeting notes when you have time.
Label: B

Message: Our payment system is rejecting every transaction.
Label: A

Message: Could you update my profile picture sometime this week?
Label: B
```

هر prompt را با «Message: ... / Label:» تمام کنید. از مدل بخواهید فقط A یا B تولید کند و temperature=0 باشد.

دیتاست - نمونه‌های دارای Gold Label

```
1. Customers are unable to complete checkout right now.
Gold: A

2. Could you review this document before Friday?
Gold: B

3. The API is returning errors for every request in production.
Gold: A

4. Please change my display name when you get a chance.
Gold: B

5. A customer says their account was deleted unexpectedly.
Gold: A
```

```
6. Can we move tomorrow's meeting to the afternoon?
Gold: B

7. Great, checkout is broken again — exactly what we needed. No customer can complete a purchase.
Gold: A

8. URGENT!!! Please update the footer copyright year whenever you have time.
Gold: B
```

نمونه‌های ۷ و ۸ عمداً فریبنده‌اند، اما Gold آن‌ها مشخص است. هدف بررسی حساسیت مدل به wording سطحی و امکان خطای با confidence بالاست؛ تضمینی نیست که مدل حتماً اشتباه کند.

Probe samples _ بدون Gold قطعی

```
9. One user cannot log in after changing their password.

10. The dashboard is loading much more slowly than usual.
```

نمونه‌های ۹ و ۱۰ را در accuracy حساب نکنید.

مرحله A – Predictions بدون logprobs

#	Prediction	Gold
1		A
2		B
3		A
4		B
5		A
6		B
7		A
8		B
9		—
10		—

مرحله B - دریافت Logprobs

برای اولین token خروجی، top logprobsرا بگیرید. هدف پیدا کردن P(A) و P(B) است. منتور helper آماده را در اختیار شما قرار می‌دهد تا فاصله، newlineو حروف کوچک/بزرگ مدیریت شوند.

```
import math
import math
```

```
def normalize_label(token):
    return token.strip().upper()


def extract_label_probs(choice, labels=("A", "B")):
    """
    Find the first generated position where all target labels
    appear in top_logprobs, then return normalized probabilities.
    """
    if choice.logprobs is None or not choice.logprobs.content:
        return None
    for token_info in choice.logprobs.content:
        top_logprobs = token_info.get("top_logprobs", [])
        raw_probs = {label: 0.0 for label in labels}
        seen = set()
        for item in top_logprobs:
            token = normalize_label(item["token"])
            logprob = item["logprob"
            if token in raw_probs:
                raw_probs[token] = max(
                    raw_probs[token],
                    math.exp(logprob)
                )
                seen.add(token)

        if all(label in seen for label in labels):
            total = sum(raw_probs.values())
            if total == 0:
                return None
            return {
                label: raw_probs[label] / total
                for label in labels
```

```
    }
return None
```

این helper فقط برای استخراج احتمال دو label یعنی Aو Bاز خروجی logprobsاست.

لازم نیست جزئیات پیاده‌سازی این تابع را حفظ کنید. نگران نشید. کد رو ببینید متوجه میشید چیکار کرده.

کافی است کد را اجرا کنید و از خروجی آن در مراحل بعد استفاده کنید.

اگر یکی ازlabel ها در top_logprobsپیدا نشد، مقدار top_nرا بیشتر کنید و دوباره اجرا کنید.

اگر مثلاً P(A)=0.40 و P(B)=0.35 باشد، برای مقایسه‌ی دو label مجاز normalize کنید

score_A=0.40/(0.40+0.35)

score_B=0.35/(0.40+0.35).

مرحله Confidence Table - C

برای پر کردن جدول:

Prediction یعنی label ای که probability نرمال‌شده‌ی بیشتری دارد.

Confidence یعنی probabilityنرمال‌شده‌ی همان label پیش‌بینی‌شده .

در این تمرین، برای سادگی، Confidence = max(P(A), P(B))

مثال:

اگر P(A)=0.70و P(B)=0.30باشد:

Prediction = A

Confidence = 0.70

اگر P(A)=0.48و P(B)=0.52باشد:

Prediction = B

Confidence = 0.52

#	P(A) normalized	P(B) normalized	Prediction	Confidence
1				
2				
3				
4				
5				
6				
7				
8				
9				

10				

نمونه‌ها را از بیشترین confidence به کمترین confidence مرتب کنید

1. سه نمونه‌ای که مدل کمترین confidence را روی آن‌ها داشت کدام‌اند؟
2. آیا نمونه‌های ۹ و ۱۰ واقعاً confidence پایین‌تری داشتند؟
3. نمونه‌های ۷ و ۸ چه شدند؟ آیا مدل به wording سطحی مثل Great یا URGENT حساس بود؟
4. آیا نمونه‌ای وجود داشت که prediction اشتباه باشد ولی confidence نسبتاً بالا باشد؟
5. اگر چنین نمونه‌ای پیدا کردید، چه چیزی درباره‌ی رابطه‌ی model confidence و correctness یاد می‌گیریم؟
6. اگر چنین نمونه‌ای پیدا نکردید، آیا می‌توان نتیجه گرفت مدل هیچ‌وقت confidently wrong نمی‌شود؟ چرا؟
7. آیا نمونه‌ای داشتید که prediction درست باشد ولی confidence پایین باشد؟
8. آیا متن مبهم همیشه باعث confidence پایین می‌شود؟

مرحله D - Human Review

دو threshold را آزمایش کنید: 0.60 و 0.90. اگر confidence کمتر از threshold بود، نمونه را برای human review بفرستید. فقط نمونه‌های ۱ تا ۸ را برای error حساب کنید.

```
if confidence < threshold:
    result = "human review"
else:
    result = prediction
```

Threshold	Auto-accepted	Human review	Wrong predictions caught
0.60			
0.90			

1. با افزایش threshold چه اتفاقی برای تعداد نمونه‌های human review افتاد؟
2. کدام threshold محافظه‌کارانه‌تر است؟
3. آیا threshold بالاتر فقط خطاها را برای review می‌فرستد؟
4. چه تعداد prediction درست هم برای انسان فرستاده شدند؟
5. اگر human review پرهزینه باشد، چه‌trade-off ی بین automation و safety ایجاد می‌شود؟
6. آیا این confidence را می‌توان مستقیماً «احتمال درست بودن مدل در دنیای واقعی» تفسیر کرد؟ چرا؟

Optional Challenge — Temperature

فقط برای گروه‌هایی که تمرین‌های اصلی را تمام کرده‌اند.

```
Message: The service has become very slow today, but users can still use it.
Label:
```

با همان few-shot prompt تمرین ۴، پنج بار با temperature=0 و پنج بار با temperature=1 اجرا کنید.

Temperature	# A	# B
0		
1		

1. آیا در temperature=0 خروجی‌ها تکرارپذیرتر بودند؟
2. آیا temperature=1 variability بیشتری ایجاد کرد؟
3. آیا بالا بردن temperature اطلاعات تازه‌ای به model داد؟
4. Temperatureبیشتر روی دانش مدل اثر دارد یا روی روش انتخابtoken ؟
5. چرا برای classification production معمولاً temperature پایین انتخاب معقول‌تری است؟