



تمرینات تحویلی - هفته ششم

زمان تحویل: جمعہ 9 تیر، 8:59 دقیقه صبح

تمرین ۱ – رگرسیون خطی

۱.۱ دیتاست California Housing را با `fetch_california_housing` بارگذاری کنید.

راهنمایی: خروجی `fetch_california_housing()` برخلاف `make_blobs` که مستقیم `X, y` برمی‌گرداند، یک شیء است که ویژگی‌ها را در `data` (یا `frame` اگر `as_frame=True` بدهید. در دو جمله بنویسید که پارامتر `as_frame` چه کار میکند؟) و هدف را در `target` نگه می‌دارد. ساده‌ترین راه:

```
from sklearn.datasets import fetch_california_housing
housing = fetch_california_housing(as_frame=True)
df = housing.frame
X = df[["MedInc"]]
y = df["MedHouseVal"]
```

با ستون `MedInc` به‌عنوان ویژگی، داده را ۷۰/۳۰ تقسیم کنید، نمودار پراکندگی رسم کنید، یک `LinearRegression` آموزش دهید و شیب، عرض از مبدأ، و R^2 را گزارش کنید.

۱.۲ همین کار را با سه ویژگی `MedInc`، `HouseAge`، `AveRooms` تکرار کنید. R^2 جدید را با حالت تک‌ویژگی مقایسه کنید – بهبود محسوس بود؟

=====

تمرین ۲ – قاعده‌ی بیز و KNN: دو روش برای تخمین یک احتمال پسین

هر دو بخش این تمرین دنبال یک چیز هستند: تخمین

```
P(class | x).
```

بخش اول این تمرین، این کار را با فرمول دقیق بیز انجام می‌دهد (وقتی توزیع‌ها را می‌دانیم)، بخش دوم همین کار را با شمردن همسایه‌ها انجام می‌دهد (وقتی توزیع را نمی‌دانیم، فقط داده داریم).

بخش الف – کنترل کیفیت در یک کارخانه‌ی بسته‌بندی

یک کارخانه‌ی بسته‌بندی کیسه‌های آرد، وزن هر کیسه را با یک ترازوی دیجیتال به‌عنوان شاخص کنترل کیفیت اندازه می‌گیرد. کیسه‌ها به دو دسته تقسیم می‌شوند: «سالم» (وزن استاندارد) و «معیوب» (کم‌وزن، ناشی از خرابی نازل پرکن). طبق آمار خط تولید:

- ۹۲٪ کیسه‌ها سالم‌اند $\rightarrow P(\text{سالم}) = 0.92$
- ۸٪ کیسه‌ها معیوب‌اند $\rightarrow P(\text{معیوب}) = 0.08$
- وزن کیسه‌های سالم: توزیع نرمال با میانگین ۱۰۰۰ گرم و انحراف معیار ۱۵
- وزن کیسه‌های معیوب: توزیع نرمال با میانگین ۹۴۰ گرم و انحراف معیار ۲۵

۲.۱ با استفاده از `scipy.stats.norm`، هر دو توزیع را تعریف کنید و چگالی‌های شرطی‌شان را روی بازه‌ی

```
np.linspace(850, 1050, 1000)
```

رسم کنید. با نگاه به نمودار، بگویید آیا این دو دسته به خوبی از هم جدا هستند یا هم‌پوشانی محسوسی دارند.

۲.۲ یک کیسه با وزن ۹۷۰ گرم از خط تولید عبور کرده. مقادیر وزن‌دار

$P(\text{سالم}) \times p(x | \text{سالم})$

9

$P(\text{معیوب}) \times p(x | \text{معیوب})$

را در $x=970$ محاسبه کنید (دستی یا با کد). قاعده‌ی بهینه‌ی بیز این کیسه را سالم می‌داند یا معیوب؟

بخش ب – KNN: طبقه‌بندی نوع شراب

۲.۴ دیتاست Wine را با `sklearn.datasets.load_wine` بارگذاری کنید.

راهنمایی: `load_wine()` هم مثل `fetch_california_housing()` یک شیء با `data` و `target` برمی‌گرداند، نه یک tuple ساده مثل `make_blobs`. راحت‌ترین راه گرفتن مستقیم `X` و `y`:

```
X, y = load_wine(return_X_y=True)
```

داده را ۷۰/۳۰ با `stratify=y` تقسیم کنید و با `StandardScaler` مقیاس‌بندی کنید. سه مدل `KNeighborsClassifier` با $k=5$ ، $k=1$ ، و $k=15$ آموزش دهید و دقت هر کدام را روی داده آزمون گزارش کنید. با توجه به این سه دقت، بگویید کدام مقدار k بیشتر در معرض بیش‌برازش (overfitting) است و کدام بیشتر در معرض کم‌برازش (underfitting) – دلیلتان را به رفتار مدل با k کوچک در مقابل k بزرگ ربط دهید.

۲.۵ در دو یا سه جمله توضیح دهید چرا اینجا مقیاس‌بندی با `StandardScaler` لازم بود.

=====

تمرین ۳ – رگرسیون لجستیک: تایتانیک

از فایل [titanic.csv](#) استفاده کنید شامل ستون‌های `Pclass`، `Sex`، `Age`، `Fare`، و ستون هدف `Survived`.

۳.۱ فقط ستون‌های `Pclass`، `Sex`، `Age`، `Fare` را نگه دارید (`Age` را با میانگین پر کنید، `Sex` را `get_dummies` کنید). داده را ۷۰/۳۰ با `stratify=y` تقسیم، با `StandardScaler` مقیاس‌بندی، و یک `LogisticRegression` آموزش دهید. `Accuracy` را گزارش کنید.

۳.۲ Confusion Matrix را چاپ کنید و بگویید مدل کدام گروه (بازمانده یا غیربازمانده) را بیشتر اشتباه تشخیص می‌دهد. سپس `_coef` را چاپ کنید و بگویید کدام ویژگی بیشترین تأثیر مثبت/منفی را روی احتمال بقا داشته – با شهودتان از فیلم همخوانی دارد؟

۳.۳ با `predict_proba`، برای یک پیش‌بینی درست و یک پیش‌بینی غلط، مقدار

```
cross_entropy_loss(p,y)
```

را حساب کنید و مقایسه کنید.

=====

تمرین ۴ – درخت تصمیم

بخش الف – محاسبات دستی

۴.۱ فرض کنید ریشه‌ی یک درخت شامل ۲۴۰ بیمار سالم و ۶۰ پرخطر است. Gini و Entropy این گره را حساب کنید. سپس فرض کنید بر اساس «سن» به دو فرزند تقسیم شده (چپ: ۱۸۰ سالم/۱۰ پرخطر، راست: ۶۰ سالم/۵۰ پرخطر) – میانگین وزنی Gini فرزندان و Information Gain این تقسیم را حساب کنید.

۴.۲ با یک مثال شبیه XOR، در چند جمله توضیح دهید چرا درخت تصمیم می‌تواند الگویی را یاد بگیرد که رگرسیون لجستیک (با مرز خطی‌اش) از پسش بر نمی‌آید.

بخش ب – روی داده‌ی تایتانیک (همان X و y تمرین ۳)

۴.۳ با همان X و y تمرین ۳.۱، یک

```
DecisionTreeClassifier(max_depth=4)
```

آموزش دهید. Accuracy را با رگرسیون لجستیک (۳.۱) مقایسه کنید و `_feature_importances` را با ضرایب تمرین ۳.۲ مقایسه کنید – مهم‌ترین ویژگی از دید دو مدل یک‌یه؟

بخش ج – روی داده‌ی heart.csv

از دیتاست [heart.csv](#) استفاده کنید، شامل ستون‌هایی مثل `age`، `chol`، `thal` و ستون هدف `target`.

۴.۴ دیتاست را بارگذاری کنید (مقادیر خالی را یا پر کنید یا حذف کنید)، ۷۰/۳۰ با `stratify=y` تقسیم کنید. سه مدل `DecisionTreeClassifier` بسازید: بدون محدودیت، با `min_samples_leaf=20`، و با `max_leaf_nodes=8`.

Accuracy آموزش و آزمون هرکدام را گزارش کنید و بگویید کدام بیشترین نشانه‌ی بیش‌برازش را دارد. آیا مقیاس‌بندی برای این مدل‌ها لازم بود؟

۴.۵ (امتیازی) عمق درخت را از ۱ تا ۸ روی داده‌ی تایتانیک تغییر دهید و دقت آزمون هر عمق را رسم کنید – از کجا به بعد بهبود دیگر محسوس نیست؟