

سؤال ۱ – تشخیص نوع مسئله، انتخاب مدل و معیار ارزیابی

در زیر شش سناریو از حوزه‌های مختلف آمده است.

بخش اول – Implement / Observe

برای هر یک از سناریوهای زیر مشخص کنید مسئله از نوع Regression است یا Classification:

- پیش‌بینی مدت‌زمانی که یک کاربر یک ویدیوی آموزشی آنلاین را قبل از خروج تماشا می‌کند (بر حسب دقیقه).
- تشخیص اینکه یک نظر ثبت‌شده روی محصول یک فروشگاه اینترنتی «مثبت» است یا «منفی».
- پیش‌بینی مصرف انرژی روزانه یک ساختمان اداری بر اساس دما، تعداد کارکنان و مساحت.
- تشخیص اینکه آیا یک تراکنش کارت بانکی مشکوک به کلاهبرداری است یا خیر.
- پیش‌بینی زمان تقریبی رسیدن یک مرسوله پستی بر اساس فاصله و روش ارسال.
- دسته‌بندی مشتریان یک فروشگاه آنلاین به گروه‌های رفتاری، بدون داشتن هیچ برچسبی از قبل.

جدول زیر را برای هر سناریو تکمیل کنید.

الگوریتم را از میان Linear Regression، Logistic Regression، KNN Regressor، KNN Classifier، Decision Tree Classifier و K-Means انتخاب کنید.

معیار ارزیابی را از میان R^2 ، MSE، MAE، Precision/Recall/F1، Accuracy، Confusion Matrix، یا در صورت عدم امکان سنجش با معیارهای Classification، خالی بگذارید.

سناریو	نوع مسئله	الگوریتم پیشنهادی	معیار ارزیابی
1	...	...	...
2	...	...	...
3	...	...	...
4	...	...	...
5	...	...	...
6	...	...	...

بخش دوم – Reason

الف) سناریوی ۶ (دسته‌بندی مشتریان بدون برچسب) را با سناریوی ۲ (تشخیص نظر مثبت/منفی) مقایسه کنید. چرا نمی‌توان برای سناریوی ۶ از معیارهایی مانند Accuracy یا F1-score استفاده کرد؟

ب) در سناریوی ۴ (تشخیص تراکنش مشکوک)، معمولاً تعداد تراکنش‌های واقعاً متقلبانه بسیار کمتر از تراکنش‌های سالم است. با توجه به این موضوع، چرا بالا بودن Accuracy به‌تنهایی نمی‌تواند نشان‌دهنده مدل خوبی باشد؟ (پاسخ مفهومی کافی است؛ در سؤال ۳ همین موضوع را با داده واقعی مشاهده خواهید کرد).

ج) تفاوت اصلی خروجی یک مدل Regression و یک مدل Classification را در سناریوهای ۱ و ۲ توضیح دهید. این تفاوت چه اثری روی نوع معیار ارزیابی می‌گذارد؟

سؤال ۲ – رگرسیون خطی برای پیش‌بینی نمره کوییز آنلاین

یک پلتفرم آموزش آنلاین می‌خواهد بر اساس رفتار کاربران در طول یک دوره، نمره نهایی آن‌ها را در کوییز پایانی پیش‌بینی کند. دیتاست زیر شامل ۶۰ دانشجو با چهار ستون است.

```
import pandas as pd

quiz_data = pd.DataFrame({
    "study_hours":
    [4.8,11.4,8.9,7.4,2.3,2.3,1.2,10.5,7.4,8.6,0.7,11.7,10.1,2.9,2.6,2.6,4.0,6.5,5.5,3.8,7.5,2.1,3.9,4.7,5.7,9.5,2.8,6.
    4,7.3,1.0,7.5,2.5,1.2,11.4,11.6,9.8,4.0,1.6,8.4,5.6,1.9,6.2,0.9,11.0,3.5,8.1,4.1,6.5,6.8,2.6,11.7,9.4,11.3,10.8,7.
    4,11.1,1.5,2.8,1.0,4.2],
    "videos_watched":
    [15,12,17,14,20,23,24,12,8,14,12,0,24,6,8,23,0,11,7,23,10,18,16,7,2,2,0,4,9,6,8,6,8,7,11,1,0,15,22,22,23,4,2,
    11,7,21,2,0,2,4,14,13,2,0,4,22,13,6,8,14],
    "practice_solved":
    [14,25,12,31,38,31,3,29,36,22,38,14,28,35,12,31,6,21,27,1,5,27,27,19,29,10,27,24,38,32,0,26,12,2,38,5,7,26
    ,8,36,32,23,14,31,31,23,11,38,1,2,36,16,1,1,27,22,36,31,32,0],
    "quiz_score":
    [59.7,94.2,82.2,83.1,72.2,62.8,43.3,97.3,78.1,88.6,61.2,86.6,97.9,59.2,43.3,72.4,48.4,74.1,66.6,54.6,67.3,55.
    2,68.7,54.5,67.1,69.7,47.2,62.9,81.4,50.7,64.3,53.8,44.5,88.3,100.0,67.1,36.4,59.6,85.4,80.9,68.6,69.8,35.0,1
    00.0,60.6,82.2,50.8,77.4,55.7,32.3,100.0,77.8,76.1,74.3,74.4,100.0,55.3,56.6,44.6,47.0]
})
```

توضیح ستون‌ها:

ستون	توضیح
study_hours	ساعات مطالعه دانشجو در طول دوره
videos_watched	تعداد ویدیوهای آموزشی تماشا شده
practice_solved	تعداد تمرین‌های حل شده
quiz_score	نمره نهایی کوییز Regression از ۰ تا ۱۰۰

بخش اول – Implement

الف) داده‌ها را با نسبت ۸۰٪ آموزش و ۲۰٪ آزمون تقسیم کنید (از `random_state=42` استفاده کنید).

ب) یک مدل `LinearRegression` با استفاده از سه ویژگی `study_hours`، `videos_watched` و `practice_solved` برای پیش‌بینی `quiz_score` آموزش دهید.

ج) روی داده آزمون، مقادیر `MSE`، `MAE` و R^2 را محاسبه کنید.

د) نموداری از Predicted در مقابل Actual رسم کنید و خط ایده‌آل ($y = x$) را نیز روی آن نمایش دهید.

ه) ضرایب مدل (`_coef`) را به همراه نام هر ویژگی چاپ کنید.

بخش دوم – Observe

مقدار	معیار
...	MAE
...	MSE
...	R^2

ضریب ($_{coef}$)	ویژگی
...	study_hours
...	videos_watched
...	practice_solved

بخش سوم – Reason

الف) بر اساس ضرایب به دست آمده، کدام ویژگی بیشترین تأثیر مثبت را روی نمره کوییز دارد؟ آیا این نتیجه با شهود شما همخوانی دارد؟

ب) با نگاه به نمودار Predicted vs Actual، آیا نقاط عموماً نزدیک خط ایده آل قرار گرفته اند؟ اگر چند نمونه فاصله زیادی از خط داشته باشند، چه برداشتی می توان از آن ها داشت؟

ج) فرض کنید یکی از دانشجویان می گوید: «مقدار R^2 من برابر با ۰.۷۸ است، پس مدل من قطعاً برای پیش بینی هر دانشجوی جدید قابل اعتماد است.» این ادعا را نقد کنید و توضیح دهید R^2 بالا دقیقاً چه چیزی را تضمین می کند و چه چیزی را تضمین نمی کند.

د) اگر ویژگی videos_watched را از مدل حذف کنیم، انتظار دارید مقدار R^2 افزایش یابد، کاهش یابد یا تغییر محسوسی نکند؟ دلیل خود را بر اساس ضریب به دست آمده برای این ویژگی توضیح دهید.

بخش اول – Implement

(الف) پنج سطر اول داده را نمایش دهید. سپس تعداد نمونه‌های هر کلاس (۰ و ۱) را در ستون churned محاسبه کنید و درصد هر کلاس را گزارش کنید.

(ب) داده‌ها را به نسبت ۸۰٪ آموزش و ۲۰٪ آزمون تقسیم کنید. از `random_state=42` و `stratify=y` استفاده کنید تا نسبت کلاس‌ها در هر دو مجموعه حفظ شود.

(ج) ویژگی‌ها را با `StandardScaler` استانداردسازی کنید، سپس یک مدل `LogisticRegression` آموزش دهید.

(د) روی داده آزمون، `Accuracy`، `Precision`، `Recall` و `F1-score` را محاسبه کنید و `Confusion Matrix` را نمایش دهید.

بخش دوم – Observe

مقدار	معیار
...	Accuracy
...	Precision
...	Recall
...	F1-score

FN	FP	TN	TP
...	...	...	...

بخش سوم – Reason

(الف) با توجه به درصدی که در بخش (الف) از قسمت Implement محاسبه کردید، آیا داده churned متوازن است؟ اگر یک مدل ساختگی همیشه پیش‌بینی «لغو نکرده» (۰) را برگرداند، `Accuracy` آن تقریباً چند درصد خواهد بود؟ (بدون اجرای کد، فقط بر اساس درصد کلاس‌ها استدلال کنید.)

(ب) با مقایسه `Accuracy` مدل واقعی خود با تخمین بخش قبل، توضیح دهید چرا در این مسئله `Accuracy` به‌تنهایی معیار قابل‌اعتمادی نیست و کدام معیار (`Precision` یا `Recall`) اهمیت بیشتری دارد؟ دلیل خود را بر اساس هزینه از دست دادن یک مشتری در حال ترک (FN) در مقابل هشدار اشتباه به مشتری وفادار (FP) توضیح دهید.

(ج) اگر باشگاه تصمیم بگیرد به همه مشتریانی که مدل آن‌ها را «در خطر ترک» تشخیص می‌دهد، کد تخفیف بدهد، کدام نوع خطا (FN یا FP) برای باشگاه هزینه کمتری دارد؟ توضیح دهید.

(د) `predict_proba` مدل را برای داده آزمون استخراج کنید. اگر آستانه تصمیم‌گیری را از ۰.۵ به ۰.۳ کاهش دهیم، انتظار دارید `Recall` افزایش یابد یا کاهش؟ `Precision` چگونه؟ پاسخ خود را با یک بار اجرای مدل با `threshold=0.3` تأیید کنید.

سؤال ۴ – پیش‌بینی قیمت بلیط پرواز با KNN Regressor

بررسی اثر K و اهمیت استانداردسازی در الگوریتم‌های مبتنی بر فاصله

یک سامانه رزرو بلیط هواپیما می‌خواهد قیمت تقریبی بلیط را بر اساس فاصله زمانی تا پرواز، مسافت مسیر و تعداد توقف‌ها پیش‌بینی کند. دیتاست زیر شامل ۵۵ پرواز است.

```
import pandas as pd

flight_data = pd.DataFrame({
    "days_before_flight":
    [26,64,81,82,56,14,77,34,72,83,25,49,33,46,5,35,13,2,75,38,85,82,25,18,68,71,44,65,80,24,28,71,1,
    1,58,28,45,15,8,56,80,65,41,28,6,54,72,51,60,2,4,9,88,82,69,73],
    "distance_km":
    [575,2245,1234,3510,2458,1752,564,1229,685,1291,4245,718,319,3456,2142,743,793,1140,1362,2,
    259,419,4258,4171,3104,3216,3504,2533,2669,2088,4486,930,4032,662,3818,4016,3190,4378,198,
    5,1231,2813,2866,4244,2077,614,3949,1424,4340,1105,1929,2600,3550,4009,2305,2051,2358],
    "num_stops":
    [0,1,0,1,0,0,2,2,2,0,0,2,0,1,1,1,0,1,2,2,2,2,0,1,2,2,0,0,2,1,1,2,0,1,1,2,2,1,2,2,1,1,0,2,1,2,1,0,1,0,2,0,2,
    2,1],
    "ticket_price_usd":
    [335,380,275,391,458,431,61,331,133,233,683,214,308,506,476,298,402,480,162,390,63,425,705,5,
    69,368,400,474,375,233,703,354,443,380,492,571,475,663,495,207,287,401,595,453,357,544,189,
    552,254,476,609,611,456,224,246,315]
})
```

توضیح ستون‌ها:

ستون	توضیح
days_before_flight	تعداد روز باقی‌مانده تا پرواز در لحظه خرید بلیط
distance_km	مسافت مسیر پرواز (کیلومتر)
num_stops	تعداد توقف‌های میان‌راه (۰ = مستقیم)
ticket_price_usd	قیمت بلیط (دلار) – هدف Regression

بخش اول – Implement

الف) داده‌ها را به نسبت ۸۰٪ آموزش و ۲۰٪ آزمون تقسیم کنید (random_state=42).

ب) قبل از آموزش مدل، ویژگی‌ها را با StandardScaler استانداردسازی کنید (دقت کنید مقیاس days_before_flight و distance_km بسیار متفاوت است). سپس یک مدل KNeighborsRegressor با n_neighbors=5 آموزش دهید.

ج) روی داده آزمون، مقادیر MSE، MAE و R^2 را محاسبه کنید.

د) مدل را برای مقادیر K برابر با ۱، ۳، ۵، ۷، ۹ و ۱۵ دوباره آموزش دهید (هر بار روی داده استانداردشده) و مقدار R^2 را برای هرکدام ثبت کنید.

ه) برای پروازی با $distance_km=2000$ ، $days_before_flight=20$ و $num_stops=1$ قیمت را با بهترین مقدار K پیش‌بینی کنید.

بخش دوم – Observe

MAE	MSE	R^2
...	...	...

K	R^2
1	...
3	...
5	...
7	...
9	...
15	...

بخش سوم – Reason

الف) بر اساس جدول K و R^2 ، بهترین مقدار K کدام است؟ آیا رابطه بین K و R^2 به صورت یکنواخت (همیشه صعودی یا همیشه نزولی) است یا یک نقطه بهینه دارد؟

ب) اگر $K=1$ باشد، مدل نسبت به نویز داده‌های آموزش چه حساسیتی دارد؟ اگر K برابر با تعداد کل نمونه‌های آموزش باشد، مدل چه پیش‌بینی‌ای برای همه ورودی‌ها انجام می‌دهد؟

ج) فرض کنید هم‌کلاسی شما فراموش کرده ویژگی‌ها را استانداردسازی کند و مستقیماً $days_before_flight$ (بازه ۱ تا ۹۰) و $distance_km$ (بازه ۳۰۰ تا ۴۵۰۰) را در KNN استفاده کرده است. توضیح دهید چرا در این حالت فاصله اقلیدسی عملاً تحت تأثیر یک ویژگی ($distance_km$) قرار می‌گیرد و ویژگی $days_before_flight$ تقریباً بی‌اثر می‌شود.

د) چرا KNN را یک الگوریتم Lazy Learning می‌نامند؟ این ویژگی چه تأثیری روی زمان پیش‌بینی (نه آموزش) دارد، اگر تعداد پروازهای دیتاست ده برابر شود؟

سؤال ۵ – Bias–Variance Tradeoff و Overfitting, Underfitting

تشخیص تقلب (Cheat Detection) در یک بازی ویدیویی آنلاین با Decision Tree

یک شرکت بازی‌سازی می‌خواهد بر اساس آمار بازیکنان (دقت شلیک، زمان واکنش، درصد Headshot و تعداد گزارش‌های مشکوک)، تشخیص دهد آیا یک بازیکن از تقلب استفاده می‌کند یا خیر. برای تولید داده مصنوعی اما واقع‌گرایانه، از `make_classification` در `sklearn` استفاده می‌کنیم.

```
from sklearn.datasets import make_classification

X, y = make_classification(
    n_samples=400,
    n_features=4,
    n_informative=3,
    n_redundant=0,
    n_clusters_per_class=2,
    weights=[0.82, 0.18], # کلاس ۱ (تقلب) کمتر از کلاس ۰ است
    flip_y=0.05,          # کمی نویز واقع‌گرایانه در برچسب‌ها
    class_sep=0.9,
    random_state=42
)

# نامگذاری ویژگی‌ها برای خوانایی بیشتر
feature_names = ['accuracy_pct', 'reaction_time_ms', 'headshot_rate_pct', 'reports_count']
```

این کد چهار ویژگی رفتاری بازیکن و برچسب `is_cheater` (۱ = مشکوک به تقلب، ۰ = عادی) را می‌سازد. توجه کنید کلاس‌ها نامتوازن هستند (حدود ۱۸٪ نمونه‌ها تقلب‌کننده‌اند) و `flip_y=0.05` باعث می‌شود کمی همپوشانی و نویز واقعی بین دو کلاس وجود داشته باشد – دقیقاً مثل داده‌های واقعی که هرگز کاملاً تمیز نیستند.

بخش اول – Implement

الف) داده را به نسبت ۷۰٪ آموزش و ۳۰٪ آزمون تقسیم کنید. از `random_state=42` و `stratify=y` استفاده کنید.

ب) سه مدل Decision Tree زیر را روی داده آموزش، آموزش دهید:

```
DecisionTreeClassifier(max_depth=1, random_state=42) # مدل اول
DecisionTreeClassifier(max_depth=4, random_state=42) # مدل دوم
DecisionTreeClassifier(random_state=42)              # مدل سوم — بدون محدودیت عمق
```

ج) برای هر مدل، Accuracy را هم روی داده آموزش و هم روی داده آزمون محاسبه کنید.

بخش دوم – Observe

مدل	Train Accuracy	Test Accuracy	اختلاف Train - Test
max_depth=1	...	...	...
max_depth=4	...	...	...
بدون محدودیت عمق	...	...	...

بخش سوم – Reason

الف) کدام مدل دچار Underfitting شده است؟ پاسخ خود را بر اساس مقدار Accuracy روی داده آموزش (نه فقط آزمون) توضیح دهید – یک مدل Underfit چه رفتاری روی خود داده آموزش دارد؟

ب) کدام مدل دچار Overfitting شده است؟ چه رابطه‌ای بین Train Accuracy و Test Accuracy، نشانه Overfitting است؟

ج) کدام مدل بهترین Generalization را دارد؟ پاسخ را بر اساس کمترین اختلاف Train - Test توجیه کنید، نه صرفاً بر اساس بالاترین Test Accuracy.

د) اکنون مفهوم Bias–Variance Tradeoff را با نتایج بالا پیوند دهید: مدل max_depth=1 نمونه کدام حالت (Bias بالا / Variance بالا) است؟ مدل بدون محدودیت عمق چگونه است؟ در یک یا دو جمله توضیح دهید چرا.

ه) فرض کنید تیم بازی‌سازی این مدل را روی سرور واقعی و برای بازیکنان جدید اجرا می‌کند. کدام یک از سه مدل را پیشنهاد می‌دهید؟ چرا Test Accuracy بالا به‌تنهایی برای این تصمیم کافی نیست و باید به اختلاف Train/Test نیز توجه کرد؟

سؤال ۶ – خوشه‌بندی رفتار شنوندگان موسیقی با K-Means

کشف الگوهای پنهان بدون برچسب و مقایسه با Classification

یک پلتفرم پخش موسیقی می‌خواهد بدون هیچ برچسب از پیش‌تعیین‌شده‌ای، کاربران خود را بر اساس رفتار گوش‌دادن به گروه‌های رفتاری مشابه تقسیم کند. دیتاست زیر شامل ۴۸ کاربر با دو ویژگی است.

```
import pandas as pd

listener_data = pd.DataFrame({
    "weekly_listening_hours":
[9.4,3.0,4.6,29.3,27.2,9.6,31.9,16.8,8.2,12.3,4.7,8.8,32.3,8.2,21.8,1.4,5.8,25.3,22.7,22.2,15.7,2.2,31.
5,25.1,2.5,12.3,32.4,4.7,4.0,25.9,4.8,3.3,2.2,4.4,11.1,12.7,17.6,11.5,24.2,17.1,23.9,14.7,5.0,3.1,17.7
,20.3,30.2,5.5],
    "followed_genres_count":
[5,1,3,11,14,7,11,7,4,8,1,4,12,7,12,3,1,14,11,10,6,2,12,12,1,6,14,1,3,8,3,3,1,2,6,5,4,5,12,5,14,5,2,3,
7,8,12,3]
})
```

توضیح ستون‌ها:

ستون	توضیح
weekly_listening_hours	ساعات گوش‌دادن به موسیقی در هفته
followed_genres_count	تعداد ژانرهای دنبال‌شده توسط کاربر

توجه: این دیتاست هیچ ستون برچسبی (Target) ندارد.

بخش اول – Implement

(الف) داده‌ها را بررسی کنید: پنج سطر اول را نمایش دهید و تعداد کل نمونه‌ها را مشخص کنید.

(ب) ویژگی‌ها را با StandardScaler استانداردسازی کنید.

(ج) یک مدل KMeans با n_clusters=3 و random_state=42 آموزش دهید.

(د) برچسب خوشه هر کاربر را به دیتاست اضافه کنید و نموداری پراکندگی (Scatter Plot) رسم کنید که در آن رنگ هر نقطه بر اساس شماره خوشه‌اش باشد. مراکز خوشه‌ها (Centroids) را نیز روی همان نمودار نمایش دهید.

(ه) مختصات مراکز سه خوشه را چاپ کنید (توجه: چون داده استانداردسازی شده، برای تفسیر بهتر می‌توانید میانگین هر ویژگی را به‌ازای هر خوشه از داده اصلی (غیر استاندارد) نیز محاسبه و گزارش کنید).

بخش دوم – Observe

تعداد اعضا	میانگین followed_genres_count	میانگین weekly_listening_hours	شماره خوشه
...	...	...	0
...	...	...	1
...	...	...	2

بخش سوم – Reason

الف) با نگاه به میانگین‌های جدول بالا، برای هر یک از سه خوشه یک نام معنادار انتخاب کنید (مثلاً «شنونده گاه‌به‌گاه»، «شنونده متعادل»، «شنونده پرمصرف چندژانره»). نام‌ها باید صرفاً بر اساس خروجی واقعی مدل شما انتخاب شوند.

ب) آیا شماره خوشه (۰، ۱ یا ۲) نشان‌دهنده ترتیب یا کیفیت خوشه‌هاست؟ توضیح دهید چرا اگر مدل را دوباره اجرا کنید (حتی با همان داده)، ممکن است شماره‌های خوشه‌ها با محتوای متفاوتی جابه‌جا شوند.

ج) چرا برای سنجش کیفیت این خوشه‌بندی نمی‌توان از معیارهایی مانند Accuracy یا F1-score استفاده کرد؟ این تفاوت را با سؤال ۳ (که در آن از Precision/Recall استفاده کردید) مقایسه کنید.

د) مدل KMeans را یک‌بار با $n_clusters=2$ و یک‌بار با $n_clusters=6$ اجرا کنید. با مشاهده نمودارهای جدید، توضیح دهید: آیا افزایش تعداد خوشه‌ها همیشه به معنای خوشه‌بندی «بهتر» است؟ اگر $n_clusters$ را برابر با تعداد کل نمونه‌ها (۴۸) قرار دهیم، چه اتفاقی می‌افتد و چرا این حالت بی‌فایده است؟

سؤال چالشی (اختیاری) – پیش‌بینی خطر قطعی برق در خانه‌های هوشمند

یک شرکت انرژی روی خانه‌های مشترک خود سنسورهایی نصب کرده که داده‌های عملکردی را ثبت می‌کنند. هدف، پیش‌بینی احتمال وقوع «قطعی پرخطر برق» در یک بازه گرم سال است تا نگهداری پیشگیرانه انجام شود. این مسئله دو ویژگی چالش‌برانگیز دارد: کلاس هدف بسیار نامتوازن است (فقط حدود ۱۰٪ خانه‌ها در معرض خطرند) و ارزیابی درست مدل نیازمند دقت بیشتری نسبت به یک Split ساده است.

```
import pandas as pd
```

```
smart_home_data = pd.DataFrame({
    "temperature_c":
    [-0.6,40.7,17.7,6.4,20.0,8.4,35.5,-3.1,0.1,31.1,-2.6,31.5,-4.6,24.1,33.5,37.2,41.3,18.3,11.6,35.8,13.7,
    25.3,-4.0,33.0,15.2,21.3,31.6,13.9,37.7,25.5,29.2,31.6,11.5,-4.1,11.9,9.3,38.2,6.9,6.3,37.8,31.5,15.2,
    38.3,28.3,-1.6,10.1,34.7,24.9,23.9,33.0,24.9,7.6,13.1,11.2,4.4,7.2,26.6,34.9,4.5,31.2,34.1,20.3,12.5,
    4.5,3.8,10.2,-1.6,4.1,38.2,23.8,-3.2,7.9,29.0,38.9,13.7,28.7,33.3,-3.6,33.9,17.5,8.2,22.9,-2.0,2.9,20.1,
    22.4,5.6,30.1,31.0,11.6,23.0,41.0,8.6,24.4,10.0,38.4,16.8,35.4,3.6,8.3,8.2,22.1,18.1,30.5,-1.8,38.6,8
    .5,20.8,19.8,18.1,39.7,23.7,14.6,15.6,6.1,41.1,30.4,8.7,8.7,29.0,18.7,-3.1,19.0,12.7,30.3,28.8,-1.4,3
    5.4,-2.2,26.0,-1.8,27.9,12.6,4.6,32.1,41.1,23.7,17.6,18.6,-2.4,-2.4,6.5,0.3,13.7,4.8,21.9,20.7,-2.8,30.
    1,-4.9,35.0,23.5,37.4,4.0,4.2,-0.5,11.0,22.2,-1.6,5.6,16.8,27.6,18.5,18.5,13.7,-1.1,25.1,19.8,6.0,34.2,
    5.5,37.8,39.3,17.9,27.0,32.9,10.2,7.2,-4.0,5.2,28.5,40.8,27.3,-3.1,32.6,6.8,4.8,4.8,22.1,-0.3,-3.7,10.4
    ,27.5,3.3,39.7,24.3,-2.3,10.2,26.9,1.1,26.7,24.1,41.2,28.2,2.6,18.5,27.7,5.8,41.6,7.1,1.2,21.8,23.9,20
    .2,21.8,6.8,-0.8,6.8,16.9,18.0,17.4,6.4,38.3,2.0,11.8,12.0,17.0,22.0,15.2,24.5,26.7,-4.0,18.0,-1.7,25.
    4,32.0,38.5,12.8,20.1,29.2,7.4,21.8,28.8,3.3,15.1,21.7,38.0,26.0,10.6,24.5,26.7,3.3,17.7,2.3,40.5,15.
    5,35.6,6.6,29.2,39.9],
    "household_size":
    [5,1,1,3,1,1,2,1,3,2,1,3,1,4,5,4,6,4,4,1,2,5,5,4,5,2,2,6,1,1,3,1,2,4,1,1,4,2,2,4,2,4,4,4,2,2,3,5,1,1,1,5,4,
    5,6,3,1,5,6,6,4,5,6,3,4,1,2,4,5,3,3,3,1,6,4,2,1,1,2,6,3,1,3,3,2,6,6,6,1,3,4,1,1,1,6,1,2,3,3,3,1,2,3,3,2,5,
    2,1,4,6,3,5,2,6,2,6,4,5,4,3,3,6,4,5,4,1,4,4,1,2,4,3,1,3,4,4,6,5,1,2,5,3,2,5,3,4,6,2,5,6,3,6,4,4,3,4,5,4,1,
    2,4,3,6,3,2,6,6,5,4,3,6,5,6,6,2,6,5,1,1,4,2,6,3,4,2,5,3,1,2,5,2,3,4,2,5,2,1,4,6,4,5,6,4,4,2,2,1,1,3,3,2,5,
    6,1,5,3,5,3,1,3,1,1,3,4,6,3,5,1,2,6,6,4,1,6,5,4,4,3,1,1,5,5,5,6,5,4,3,4,1,1,4,3,5,4,2,3,3,4,6,3],
    "ac_units":
    [0,1,2,0,1,3,2,2,0,1,0,3,1,1,3,1,1,0,3,3,1,3,1,2,2,2,1,1,3,2,0,1,0,2,1,3,2,0,3,3,0,0,1,3,3,2,1,1,3,1,2,2,1,
    3,0,2,2,2,3,3,1,3,3,3,1,2,1,1,0,1,3,1,2,0,2,0,2,0,1,1,3,2,3,0,2,2,2,2,0,0,2,0,2,0,0,0,2,0,0,1,2,1,3,1,0,3,
    0,3,0,2,1,1,1,2,0,1,1,2,0,0,2,0,2,0,3,2,0,1,3,2,3,0,3,3,1,0,0,3,1,2,3,0,3,1,0,0,1,1,1,1,1,3,2,2,1,3,0,3,3,
    0,1,1,2,3,0,0,2,0,3,0,1,1,0,3,1,3,0,1,0,0,3,2,3,1,2,0,1,3,1,0,0,0,3,0,2,1,0,1,1,3,1,3,1,3,2,3,3,1,2,1,3,3,
    1,3,1,2,1,3,1,1,1,2,3,0,2,3,3,1,3,2,1,0,0,0,2,0,1,0,3,1,1,3,3,3,1,3,2,0,0,3,3,3,3,3,2,0,2,0,0,1],
    "wiring_install_year":
    [2002,1988,2002,1983,1988,1976,1979,1985,2010,1979,1976,2006,1984,2012,2003,2018,1979,202
    0,1987,1996,1975,1994,1984,2006,2019,2004,1976,2023,2006,1985,1987,2001,1979,2016,1997,19
    81,1989,2013,1992,1989,1975,2011,1977,2020,2008,2001,2005,1985,2004,1979,1985,1989,1996,1
    989,1978,1993,2003,2018,1989,2015,1998,1983,2009,2005,2023,2002,1982,1989,2006,2006,2016,
    1982,1988,2016,1990,2003,2002,2023,2021,2005,1984,1997,1982,1996,1975,2019,2015,1996,198
    1,1976,1999,2005,2005,2017,2013,2012,1996,2012,2002,2012,1975,1995,1989,2012,2006,1984,19
    88,1988,2005,1988,2012,1989,1980,1990,2011,1977,2018,1989,2000,1982,1975,2002,2013,1979,2
    011,2017,1987,2007,1998,1987,1984,1993,1979,1983,1994,2021,2004,1995,2002,1995,1982,2009,
    1992,1991,2003,1989,1977,2003,1999,1986,2014,2022,1985,1984,2023,1987,1989,1981,2012,199
```


مقدار (Baseline)	معیار
...	Accuracy
...	Precision
...	Recall
...	F1-score

۳) Reason: عدد Accuracy این مدل بی‌فایده چقدر بالاست؟ کدام معیار (از بین Precision، Recall و F1) نقص واقعی این مدل را آشکار می‌کند و چرا دقیقاً همین معیار صفر یا نزدیک صفر می‌شود؟

بخش ج – Decision Tree در Overfitting

۱) دو مدل DecisionTreeClassifier روی داده آموزش آموزش دهید: یکی با `max_depth=None` و دیگری با `max_depth=4` (برای هر دو از `random_state=42` استفاده کنید).

۲) Accuracy هر دو مدل را روی داده آموزش و داده آزمون گزارش کنید.

مدل	Train Accuracy	Test Accuracy
<code>max_depth=None</code>	...	...
<code>max_depth=4</code>	...	...

۳) Reason: کدام مدل Overfit شده است؟ از روی چه شاخصی (نه فقط یک عدد، بلکه رابطه بین دو عدد) به این نتیجه رسیدید؟ با توجه به اینکه در این مسئله کلاس مثبت کمیاب است، توضیح دهید چرا فقط نگاه کردن به Accuracy برای تشخیص Overfitting گمراه‌کننده است و لازم است Precision/Recall را هم برای هر دو مجموعه بررسی کرد.

بخش د – ارزیابی قابل‌اعتماد با Stratified K-Fold

۱) روی مدل `max_depth=4`، یک Stratified 5-Fold Cross-Validation با معیار Recall اجرا کنید (از StratifiedKFold با `shuffle=True` و `random_state=42` استفاده کنید). میانگین و انحراف معیار ۵ نمره را گزارش کنید.

۲) همان کار را با KFold معمولی (بدون Stratify) تکرار کنید و علاوه بر نمرات، نسبت کلاس `outage_risk=1` را در هر یک از ۵ Fold چاپ کنید.

انحراف معیار Recall	میانگین Recall	روش
...	...	StratifiedKFold
...	...	KFold معمولی

Reason (۳): نسبت کلاس 1=outage_risk را در ۵ Fold دو روش با هم مقایسه کنید. توضیح دهید چرا در این داده نامتوازن، Stratified K-Fold روش ایمن‌تری است و چه اتفاقی برای نمره یک Fold خاص در KFold معمولی ممکن است بیفتد اگر آن Fold به‌طور تصادفی نمونه بسیار کمی از کلاس ۱ داشته باشد.

بخش ه – تصمیم‌گیری نهایی

فرض کنید نمرات Recall حاصل از ۵ Fold در بخش (د) این‌ها بوده‌اند: [0.55, 0.63, 0.50, 0.67, 0.58] → میانگین ≈ 0.59 ، انحراف معیار ≈ 0.06 . در همان زمان، یک تقسیم ساده Test/Train (بدون Cross-Validation) عدد ≈ 0.68 Recall داده است.

۱) چرا این دو عدد می‌توانند نتیجه‌گیری‌های متفاوتی درباره کیفیت واقعی مدل ایجاد کنند؟

۲) برای گزارش به مدیریت شرکت انرژی که می‌خواهد بداند «آیا این مدل برای استقرار در مقیاس واقعی قابل‌اعتماد است؟»، کدام‌یک از این دو نوع گزارش شواهد قوی‌تری است؟ دلیل خود را با اشاره به مفهوم واریانس نتیجه ارزیابی توضیح دهید.